



西南林业大学

SOUTHWEST FORESTRY UNIVERSITY

硕士学位论文

MASTER THESIS

论文题目 操作系统中进程管理与内存管理的设计
与实现

学科专业 林业信息工程

学 号 20151111002

作者姓名 罗志兵

指导教师 赵家刚 (副教授)

分类号 TP311密级

UDC

学 位 论 文

操作系统中进程管理与内存管理的设计与实现

罗志兵

指导教师 赵家刚 副教授
西南林业大学 昆明

申请学位级别 硕士 学科专业 林业信息工程

提交论文日期 论文答辩日期

学位授予单位和日期 西南林业大学

答辩委员会主席

DESIGN AND IMPLEMENTATION OF PROCESS AND MEMORY MANAGEMENT IN AN OPERATING SYSTEM

A Master Thesis Submitted to
Southwest Forestry University

Major: Forestry information engineering

Author: LUO Zhibing

Advisor: ZHAO Jiagang (Associate Professor)

School: College of Big Data and
Intelligence Engineering

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得西南林业大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名：_____ 日期：_____ 年 _____ 月 _____ 日

论文使用授权

本学位论文作者完全了解并同意西南林业大学有关保留、使用学位论文的规定，学校有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权西南林业大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。
(保密的学位论文在解密后应遵守此规定)

作者签名：_____ 导师签名：_____

日期：_____ 年 _____ 月 _____ 日

摘 要

操作系统是计算机里运行的最重要的软件，操作系统内核是计算机软件系统的核心，它是外围用户进程与硬件之间的必要接口，提供系统资源管理、程序控制等重要功能。操作系统内核通常包含进程管理、内存管理、文件系统、输入/输出、系统调用等功能模块。

操作系统内核的研究一直以来都是计算机技术领域研究的重点，而进程管理和内存管理更是研究的重中之重。随着硬件技术的飞速发展，配套软件技术也日新月异。为了最大限度地发挥硬件的威力，现代操作系统研发在提高系统并行处理能力方面也一直做着不懈的努力，以满足用户在一个计算机上能同时运行越来越多任务的需求。同时，近些年来，由于软件规模的增长速度远远大于内存增长的速度，于是，如何解决在有限的内存空间尽可能多地运行进程便成为了操作系统内核研究的另一重要任务。基于以上这两点，本文选择了以进程管理和内存管理两个模块为重点研究内容，探讨如何在 CPU 数量有限和内存空间有限的情况下，尽可能同时运行多个进程，并且让尽可能多的进程同时并存于内存中的问题。

在进程管理模块中，本文从进程的抽象概念出发，探讨了进程的本质，以及如何创建一个进程等问题。为了保证多个进程能轮流地、公平地使用 CPU 资源，本文实现了时间片轮转（Round Robin）调度算法。同时，为了解决多进程同时运行时出现的竞争问题，在实验中，本文采用了两种锁：spinlock 和 sleeplock。spinlock 锁用来保护那些短时间就能处理完的共享数据，而 sleeplock 则用来保护那些需要比较长时间才能处理完的共享数据。本文还提供了通过屏蔽中断和禁止进程在持有锁的情况下进入睡眠状态这两种方法来防止死锁的出现。

在内存管理方面，通过分页机制实现了对内存的抽象，为进程提供了虚拟地址空间，并通过页表将虚拟地址映射到内存中，为每个进程空间提供了保护。在存储进程的页表时，通过页表分级技术，以两级分页的方式存储页表，从而减少了系统存放页表的内存开销。本文还通过采用将内核映射到每个进程的地址空间中去的办法大大缩小了系统处理系统调用、异常和中断的时间开销。在给用户进程分配用户栈的时候，本文采用了给用户栈额外分配一个空页的方法来防止栈的溢出。在实现虚拟内存的时候，为了减少了系统创建新进程时的内存开销，本文

使用了写时复制 (copy-on-write) 技术。同时, 为了减少不必要的内存浪费, 本文使用了延迟分配的方法来处理进程运行时的内存分配。最后, 本文还为进程间的通信提供了共享内存技术。

关键字: 操作系统, 内核, 进程, 调度, 分页, 写时复制, 进程间通信, 共享内存

ABSTRACT

An operating system is the most important piece of software that runs in a computer system. The operating system kernel is in charge of managing the processes and the memory space as well as other resources within the computer. Kernel development has always been the hot spot of computer science and technology research. Nowadays, with the raising of user demands of running more and more software in one computer simultaneously, modern operating systems have been pushing forward to meet this requirement. More over, the software size is growing much faster than the speed of RAM growing. So, how to run more processes at the same time and how to store more processes in the memory has become the key point of kernel development. Based on the above reasons, this paper was decided to choose process management and memory management to be the research topic instead of a whole OS kernel.

In the process management module, this paper was started from discussing the abstract concept of a process, followed by further discussion on process creation and running. In order to schedule the processes in the system in a fair way, this paper adapted the round-robin algorithm to share the CPU among the processes within the system. To avoid the race condition caused by multiple processes sharing shared resources, two kinds of locks are introduced, a spinlock for protecting the short-term processing of shared data, and a sleeplock for protecting the long-term processing of shared data. Methods for preventing deadlocks are also presented by disabling interrupts and not allowing a process turns to sleep while holding a lock. In the memory management module, the virtual memory concept is implemented as an abstraction of physical memory to user programs. With this abstraction, processes can have their own private address space protected from each other. Besides, kernel is mapped into every process address space to reduce context switch time when dealing with traps. To reduce the page table size, two-level paging scheme is adapted, so as to save a lot of physical memory space. To solve the stack overflow problem this

paper uses a method that allocates an unmapped page right below the user stack to keep stack from overflowing. When forking processes, the copy-on-write technique is implemented to map parent pages into children processes' address space to save lots of memory space. When dealing with the processes' runtime memory allocation, this paper uses the lazy allocation technique to save unnecessary spaces. At last, shared memory is implemented to support inter-process communication.

Key words: operating system, kernel, process, scheduling, paging, copy-on-write, lazy-allocation, IPC

目录

1	绪论	1
1.1	研究的目的及意义	1
1.2	国内外研究现状	3
1.2.1	国外发展现状	3
1.2.2	国内发展现状	4
1.3	面临的问题	4
1.4	本文研究内容	5
1.5	技术路线	5
2	进程管理的设计与实现	8
2.1	总体设计模型	8
2.2	进程结构体的设计与实现	9
2.2.1	进程的地址空间	11
2.2.2	进程状态与进程控制块	12
2.2.3	内核栈	14
2.3	进程的创建与运行	14
2.3.1	fork() 函数	15
2.3.2	创建系统中的第一个进程	16
2.4	进程调度与算法实现	17
2.4.1	调度算法	17
2.4.2	进程切换的实现	18

2.4.3	调度算法的实现	20
2.5	进程的退出	21
2.5.1	testproc.c 程序输出结果分析	23
2.6	进程间同步的设计与实现	23
2.6.1	锁机制的实现	25
2.6.2	死锁	27
2.6.3	锁的种类	27
2.6.4	进程的阻塞与唤醒	30
3	内存管理的设计与实现	32
3.1	总体设计模型	32
3.2	详细设计与实现	33
3.2.1	分页机制	34
3.2.2	页表的实现	39
3.2.3	freelist 的实现	42
3.2.4	进程的地址空间	44
3.2.5	虚拟内存的实现	47
3.2.6	测试 COW	50
3.2.7	exec()	52
3.2.8	延迟分配 (lazy allocation)	54
3.3	进程间的通信 (IPC)	57
3.3.1	共享内存	57
3.3.2	共享内存的实现	58
4	总结与展望	60
4.1	总结	60
4.2	本文取得的成果与创新	60
4.3	改进的方向	61
	参考文献	62

附录 A 主要程序清单	65
A.1 进程管理相关代码	65
A.1.1 trapframe 结构体	65
A.1.2 allocproc() 函数	65
A.1.3 fork() 系统调用	66
A.1.4 swtch() 函数	67
A.1.5 scheduler() 函数	67
A.1.6 exit() 函数	68
A.1.7 wait() 函数	69
A.1.8 testproc.c 程序	70
A.1.9 sleep() 函数	71
A.2 内存管理相关代码	72
A.2.1 mappages() 函数	72
A.2.2 copyvm() 函数	72
A.2.3 页错误处理程序 (pagefault())	73
A.2.4 COW 测试程序 (testCOW.c)	74
A.2.5 exec() 函数	75
A.2.6 allocvm() 函数	77
A.2.7 loadvm() 函数	78
A.2.8 deallocvm 函数	79
A.2.9 程序 lazyalloc.c	79
A.2.10 shmget() 函数	80
A.2.11 shmat() 函数	80
A.2.12 sys_shmget() 系统调用函数	81
A.2.13 sys_shmat() 系统调用函数	81
 个人简介	 81
 导师简介	 83

获得成果目录	85
致 谢	88

插图

1-1	操作系统在计算机系统的位置	2
1-1	The position of an OS in the computer system	2
1-2	操作系统内核概览	6
1-2	OS overview	6
2-1	进程管理概要设计图	9
2-1	Process management top-level design	9
2-2	进程的逻辑结构	10
2-2	Process logical view	10
2-3	进程虚拟地址空间	11
2-3	Process virtual memory space	11
2-4	进程各状态之间的转化关系	12
2-4	Process state transition	12
2-5	ptable, proc[] 数组, 与 proc 结构体	13
2-5	ptable, proc[], and struct proc	13
2-6	进程的切换过程	19
2-6	Process context switch	19
2-7	进程切换	21
2-7	Process switch	21
2-8	临界区域与竞争	25
2-8	Critical region	25

3-1	内存管理功能模块图	33
3-1	Memory management modules	33
3-2	段式虚拟内存地址翻译过程	34
3-2	Address translation via segmentation	34
3-3	Intel 奔腾处理器的地址翻译过程	35
3-3	Intel Pentium virtual address translation	35
3-4	页号与页内偏移量	36
3-4	Page number and page offset	36
3-5	分页地址翻译的过程	37
3-5	Virtual address translation via paging	37
3-6	Intel i386 页表定义	39
3-6	Intel i386 Page Table Entry	39
3-7	32 位线性地址两级分页	39
3-7	Two-level paging virtual address	39
3-8	两级分页地址翻译过程	40
3-8	Two-level paging	40
3-9	进程的虚拟地址空间与物理内存的映射关系	45
3-9	The mapping of virtual address space and Physical address space	45
3-10	CoW 测试结果输出	51
3-10	CoW test result	51
3-11	lazyalloc.c 程序输出结果	56

程序目录

2-1	proc 结构体	13
2-1	struct proc	13
2-2	ptable 结构体	13
2-2	struct ptable	13
2-3	context 结构体	18
2-3	struct context	18
2-4	存在竞争	26
2-4	Race condition exists	26
2-5	避免竞争	26
2-5	Race condition avoided	26
2-6	spinlock 结构体	28
2-6	struct spinlock	28
2-7	acquire() 函数	29
2-7	acquire() function	29
2-8	sleeplock 结构体	29
2-8	struct sleeplock	29
2-9	acquiresleep() 函数	30
2-9	acquiresleep() function	30
3-1	PTE 标志位	39
3-1	PTE flags	39
3-2	mappages() 函数原型	40

3-2	mmapges() function prototype	40
3-3	walkpgdir() 函数	41
3-3	walkpgdir() function	41
3-4	空闲页	42
3-4	Free page pointer	42
3-5	kmem 结构体	42
3-5	struct kmem	42
3-6	kalloc() 函数	43
3-6	kalloc() function	43
3-7	kfree() 函数	44
3-7	kfree() function	44
3-8	内核在进程地址空间内的映射	46
3-8	The mapping of kernel address space in a process	46
3-9	内核空间地址映射	46
3-9	Kernel address space mapping	46
3-10	带有 pg_ref[] 数组的 kmem 结构体	48
3-10	struct kmem with pg_ref[] in it	48
3-11	pg_refInc() 函数	49
3-11	pg_refInc() function	49
3-12	exec() 工作过程 (代码节选)	53
3-12	exec() process	53
3-13	growproc() 函数	55
3-13	growproc() function	55
3-14	pagefault() 函数	56
3-14	pagefault() function	56
3-15	shm 结构体	58

1 绪论

1.1 研究的目的是意义

一台计算机由硬件和软件两部分组成。如果把一台计算机比做一个人的话，那么计算机的 CPU 和内存就类似于人的大脑，具备思考和记忆的能力。而计算机软件就可以比做是人的思想和精神，它决定了计算机能思考和记忆些什么东西，也就决定了计算机能完成什么样的工作。没装任何软件的计算机就象一个头脑空空的人，除了看起来可以很时尚、很酷之外，别无他用。

操作系统是计算机系统里运行的最重要的一个软件，如图 1-1所示，它是介于系统硬件（Hardware）和各种应用程序（Application）之间的软件。任何应用程序如果想操纵系统硬件，都要经过操作系统这一关。操作系统在计算机中的角色很类似现实社会生活中的政府，它是

- 资源管理者。所谓“资源”，笼统讲就是所有的系统硬件，包括 CPU、内存、网卡、声卡、显卡、键盘、鼠标.....它们的共同特点就是“紧缺”。系统中的众多应用程序都要“抢用”这些硬件资源。操作系统要负责协调应用程序之间的资源竞争。当然，它本身也要消耗掉一部分系统资源以维持自身的正常运转。一个低消耗、高效率的政府才会受欢迎，操作系统也是一样。
- 系统控制者。操作系统控制着系统中程序的运行，一旦发现有程序出错，或有程序非法使用系统资源，就要及时处理，以保障系统能安全、有序、高效地工作。
- 公共服务提供者。比如上面说到的，所有硬件的驱动程序只要在操作系统里保留一份就可以了，不必要每个应用程序里都携带相同的驱动程序。




图 1-1 操作系统在计算机系统的位置

Figure 1-1 The position of an OS in the computer system

自上世纪 60 年代分时系统诞生以来，时光已跨过了近 50 年。随着计算机硬件技术的突飞猛进，操作系统这一和硬件形影不离、息息相关的软件，也发生着沧海桑田的巨变。1969 年诞生的 UNIX 操作系统只有寥寥 4200 余行代码，而今天它的分支系统已遍布天下。其中，Linux 系统内核的代码量已超过了两千万行。除了通常所见的计算机上的通用型操作系统之外，随着硬件技术和网络技术的发展，各种特殊用途的操作系统也应运而生，如，手机系统、实时嵌入式系统、分布式系统、虚拟机、以及当下流行的云计算系统等等。

Linux 操作系统以其本身的开源性，以及低成本性，吸引了众多的公司为其提供技术支持，以及大量的自由开发爱好者和开发社区为其贡献代码。Linux 提倡的自由软件运动，让它迅速成为在业界中使用最广泛的系统。另外，相比其他操作系统内核，Linux 内核具有更快、更安全、更容易获得，和更灵活的特点。Linux 的开源性使得所有人可以轻松获得源代码，并且可以按照自己的个人意愿随意更改内核。所以，以 Linux 内核作为内核开发的学习模板，是最合适的选择。本文就是以 Linux 的最初版本为参考，对操作系统的实现的一次初步探索。

操作系统的功能通常包括进程管理、中断处理、内存管理、文件系统、设备驱动、网络协议、系统安全、输入输出等许多方面。其中进程管理部分提供了创建进程、运行进程、调度进程、和进程同步等功能。内存管理部分的主要功能就是为进程提供一个内存的抽象，实现进程的虚拟地址空间，为进程分配内存和回收内

存。文件系统则主要负责数据在硬盘上的存储和组织方式，并为用户进程提供一个文件操作的接口。现代操作系统最显著的特点就是实现多任务，因此负责实现多任务的进程管理和内存管理便成为了内核研究领域中的重点。基于这一点，本文便以进程管理和内存管理作为研究的方向，并广泛学习内核设计中关于进程管理与内存管理方面的知识，最后以 Linux 内核为学习模板，通过理论与实践相结合，努力实现进程管理和内存管理的各项基本功能，并争取能有所创新。

1.2 国内外研究现状

1.2.1 国外发展现状

操作系统研发一直是计算机技术研究的重要领域，而操作系统的研发主要是围绕内核的研究来展开的。内核的研究主要包含三方面：进程管理、内存管理和文件系统的研究。而进程管理和内存管理一直以来都是内核研究的热点。近年来，在操作系统研发领域中，发展势头最好的是以 linux 为内核的系统。据全球 Top500 超级计算机发布数据显示，截止到 2017 年 11 月，100% 的超级计算机都在运行 Linux 操作系统¹。linux 操作系统占据了全球 90% 的云计算服务器，并且在嵌入式系统占据了 62% 的市场份额。linux 在移动设备中也占据了 80% 的份额。桌面操作系统市场份额虽然没有服务器那么高，但也呈逐年扩大趋势。近年来，随着国际大公司 Intel、Google、IBM、甚至微软等，都在 Linux 操作系统上加大研发投入，为 Linux 操作系统的长远发展提供资金和技术支持。同时，Linux 拥有众多的开发社区，这些开发社区均由来自世界各地的优秀内核开发者组成，这些社区开发者为 Linux 内核的发展贡献了大部分的代码。现在 Linux 社区拥有大约 15600 个来自世界各地的个人开发者和来自 1400 多个公司的技术支持。这使得 Linux 内核大概每 9~10 个星期就能产生一个性能有所提升且稳定性良好的新版本。Linux 内核研究发展的方向主要是围绕着如何提升系统的运行速度这个问题而展开，其中包括了，如何更快速的让一个进程运行起来、如何更快速地进行进程切换、如何更快速的处理中断、如何更快速地实现内存分配以及如何提高文件系统的访问

¹<https://www.top500.org/statistics/list/>

速度等问题，而这些问题都主要属于进程管理、内存管理模块和文件系统模块的功能。所以，Linux 内核的研究直接推动了作为内核主要部分的进程管理和内存管理模块的发展。

1.2.2 国内发展现状

从 2001 年以来，基于 Linux 的服务器操作系统逐步发展壮大。国内几个主要的 Linux 厂商和科研机构，国防科技大学、中标软件、中科红旗等先后推出了 Linux 服务器操作系统产品，并且已经在政府、企业等领域得到了应用。目前国内涉及的操作系统研发也主要是以 Linux 内核为模板，并在此基础上拓展一些新的外围功能。目前国内发行的 Linux 版本主要有：红旗、中标、共创、新华、拓林思等，均有桌面和服务两个版本；但是，国内各发行版均基于国际社区版本发展而来，是在基于国际社区的内核开发成果上，只对操作系统的界面和外围软件做了一些改变，而实际上并没有掌握 Linux 的核心技术，基本上没有涉及对 Linux 内核里的进程管理和内存管理，文件系统这三个功能模块的研发。所以，国产 Linux 系统与国际 Linux 操作系统发行版之间存在比较大的技术差距。目前国内的 Linux 内核研究项目普遍存在着资金不足，人才缺乏的问题。因此，国内操作系统研发组织机构、厂商也都相应加大资金和人力的投入，努力做到能在内核的进程管理、内存管理和文件系统这些功能模块的发展上做出贡献，以缩小与国际 Linux 研究组织之间的差距。

1.3 面临的问题

几十年来，计算机科技一直在迅猛发展，CPU 的运算速度越来越快，内存的容量也越来越大。为了最大程度地发挥计算机硬件的效率，软件技术也在不断地进步、创新，软件功能越来越复杂，软件的规模也越来越庞大。庞大而复杂的软件总是需要更快的 CPU 和更大的内存来承载和运行。为了满足软件的需求，硬件技术就要更上层楼。硬件技术的提高又为催生规模更大、功能更复杂的软件提供了肥沃的土壤。硬件和软件之间的发展竞赛，一方面活跃了计算机产业，另一方面也

带来了不小的问题。硬件水平却一直没有能跟上软件发展的水平，在一个系统里，CPU 数量远远少于要运行的软件数量，以及内存的尺寸远远小于要运行的软件尺寸，这两个问题还始终存在着。这些问题的解决仍然依赖于更有效的 CPU 调度算法和虚拟内存技术。

本文在实验的过程中研究的主要问题有：

- 如何提高内核处理系统调用、异常、和中断的速度；
- 在多个 CPU 的系统里，如何设计调度队列和调度算法；
- 如何防止因用户传入的参数过大，导致用户栈的溢出问题；
- 在内核代码与程序代码同处于一个地址空间内的情况下，如何防止用户程序随意访问或更改内核区域的问题等。

1.4 本文研究内容

现代通用型操作系统结构复杂、功能多样，现代操作系统的开发是一项庞大而复杂的软件工程。如图 1-2所示，操作系统内核包括文件系统、进程管理、内存管理、设备驱动、硬件控制、系统调用等众多功能模块。其中任何一个内核模块的设计与开发都要求开发者具有极高的素质与经验，对系统内部的总体架构、运行机制、模块间的衔接关系等有极其深入的了解。考虑到任务的复杂性，以及时间和个人开发经验等方面的限制，在短期内独立完成上述诸多任务显然是不现实的。所以本文以 Linux 内核为参考，着重研究探讨进程与内存管理方面的设计与实现。

进程管理是操作系统内核实现进程管理的一个模块，主要功能包括进程的创建、进程的运行、进程的调度和进程间的同步几个部分。内存管理是操作系统内核管理内存这一个资源的一个模块，主要功能包括内存的格局分布、进程空间的抽象、内存分配和回收以及虚拟内存技术。

1.5 技术路线

本文的目标是设计和实现操作系统内核中的进程管理和内存管理这两个模块的功能。主要研究如何快速地创建进程、调度进程、切换进程，如何处理进程间的

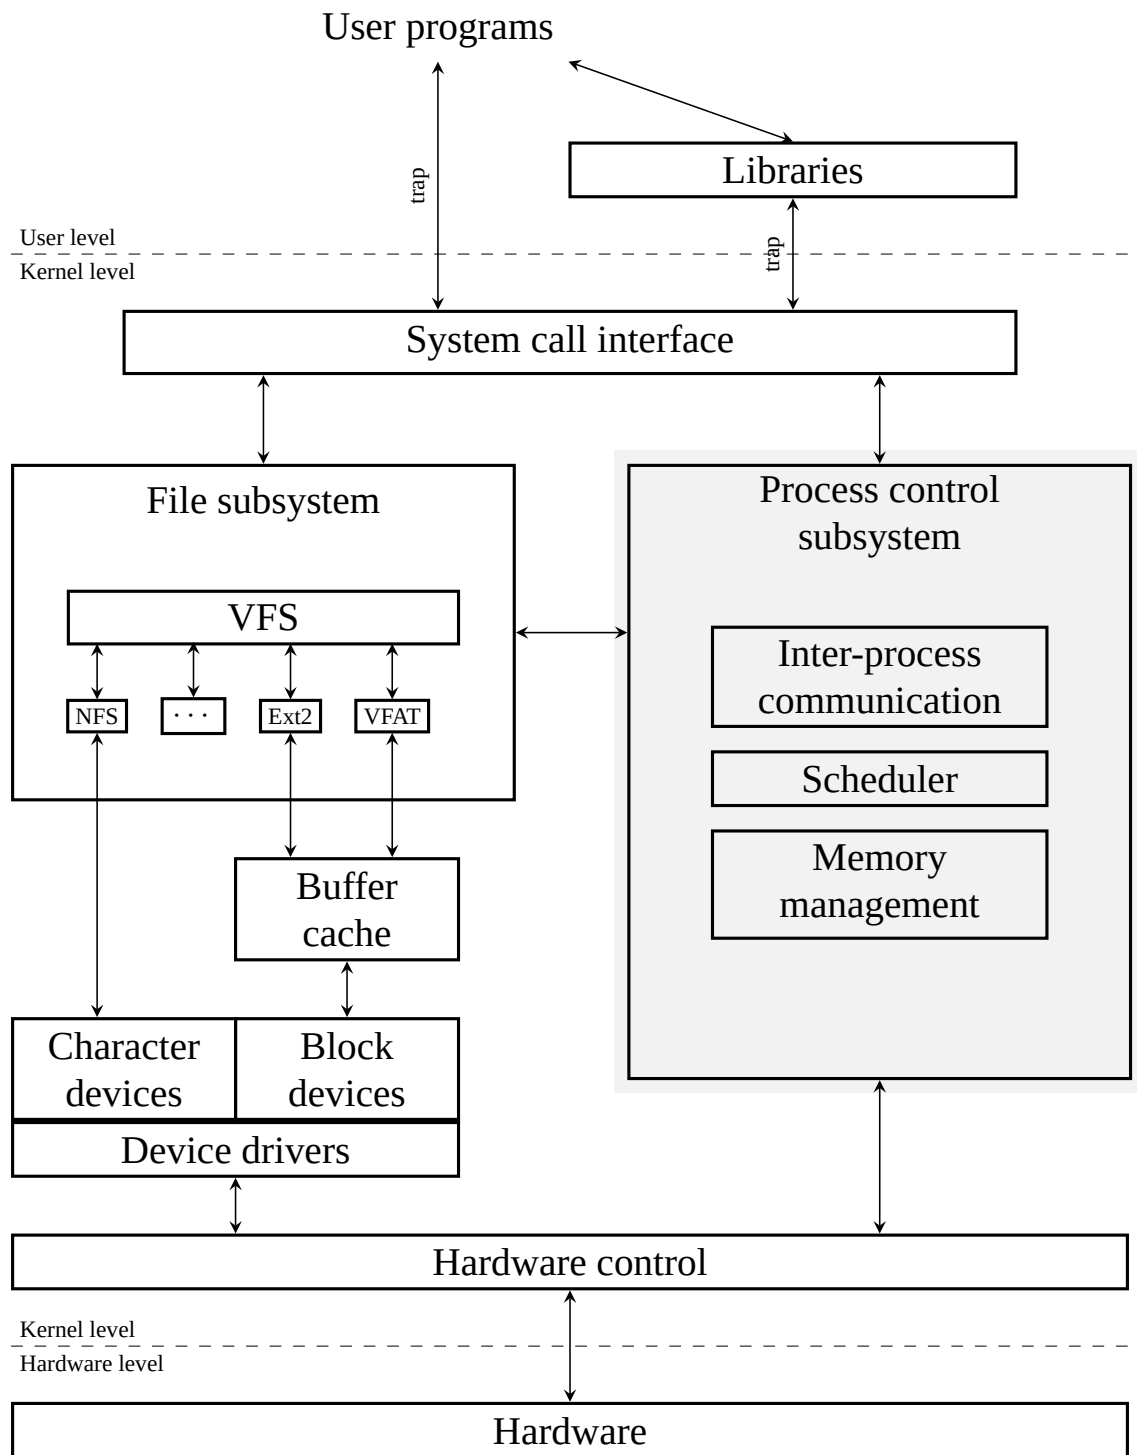


图 1-2 操作系统内核概览
Figure 1-2 OS overview

同步问题以及如何高效率地管理内存并为进程分配空间、回收空间等内容。

本文以最为常见的 Intel x86 处理器为硬件平台。软件开发环境主要包括：

- Debian GNU/Linux 9 (4.14.0-3-amd64)；
- GCC 编译器；
- GDB 调试器；
- QEMU 虚拟机。

在创建进程时，采用的是对象创建模式，用已有的对象创建新的对象，即所谓的母进程创建子进程。母进程通过调用 `fork()` 函数，来完成如下一系列操作：

1. 为子进程分配一个进程控制块，PID 号；
2. 分配内核栈；
3. 将母进程的物理内存空间与子进程共享；
4. 复制一份母进程打开的文件给予进程；
5. 为子进程提供写时复制的内存分配方法。

在调度 CPU 时，所有 CPU 共享一个就绪队列，每个 CPU 都有一个自己的调度器，为了便于实现，所有的调度器使用相同的调度算法：Round-Robin 算法；在处理进程间的同步问题时采用两种不同的锁对不同性质的共享资源提供保护。

在内存的存储管理方式上采用的是分页方式。对内存上的空闲页的管理采用的是地址池的方式。对新创建的进程的初始地址空间的分配是采用的子进程共享母进程的内存空间，并在需要进行页面复制的方法。在给进程分配用户栈的时，采用额外分配一个空页的方法来防止用户栈的溢出。在进程需要重新映射地址空间时，采取为进程重新分配并映射页表的方法。最后，在处理进程的运行时内存分配的问题上，采取了延迟分配的方法来进一步节省内存开销。

2 进程管理的设计与实现

操作系统里最重要的概念之一是进程。进程可看作是对一个正在运行的程序的一个抽象。系统里的所有工作都是围绕着这个概念而进行的。进程概念的引入，使系统得以在只有一个 CPU 的情况下也能够实现多任务的并发执行。现代的通用计算机都要能满足同时做几件事的需求。举例来说，一个网页服务器在某一个时间段内可能会收到很多个服务请求。服务器接收到一个请求之后，首先会查看缓存里是否已经存有了用户请求得到的网页，如果有的话，则可直接给用户返回，如果缓存内没有的话，则需要从硬盘内读取结果再将其返回给用户。进程在读盘的时候是用不到 CPU 的，而且读取硬盘是一个漫长的过程。如果系统没有多任务并发机制的话，在某进程读取硬盘的时候，CPU 就只能闲置，白白浪费了很多 CPU 的宝贵时间。并且别的请求由于等待时间过长，可能会被撤出内存。为了解决这一个问题，计算机系统必须具备处理并发事务的能力，通过把不同事务给模型化成一个个的进程加以控制管理。进程管理主要是解决操作系统如何创建进程，调度进程，以及如何处理进程的同步问题。其中，进程的创建是指如何创建一个新的进程，主要是通过 `fork()` 系统调用来完成。进程调度主要是让系统按照预先制定好的一个或多个调度策略来调度进程，也就是利用调度策略的规则来决定谁是下一个能占用 CPU 的进程，从而实现让多个进程以时分复用的方式共享 CPU 资源。进程同步则主要是解决多进程互相争夺共享资源时产生的冲突。

2.1 总体设计模型

本设计的进程管理部分包括进程的创建、进程的终止、进程调度、进程间同步等四个功能模块。各模块间的关系如图 2-1 所示。其中，

- 进程的创建主要解决的是如何对进程做出一个抽象的定义，如何定义进程的各种状态，如何存放进程以及如何用已有的进程创建新的进程等问题；
- 进程的运行终止主要解决的是如何处理进程退出时资源的回收问题；
- 进程的调度主要解决的是在多进程中如何合理分配 CPU 使用权的问题；
- 进程间同步指的是如何避免多进程共同访问一个共享资源时出现竞争的问题。

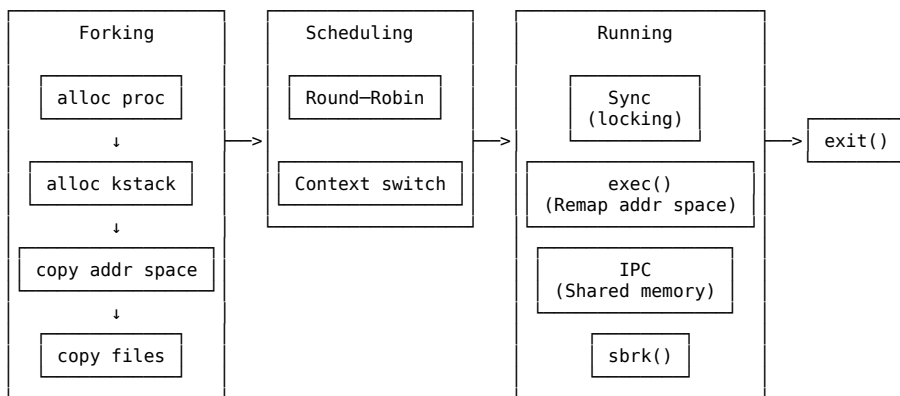


图 2-1 进程管理概要设计图

Figure 2-1 Process management top-level design

在后面的章节中，我们将详细探讨各功能模块的设计与实现。

2.2 进程结构体的设计与实现

进程是正在运行的程序的一个实例，是操作系统里最重要的概念之一。实际上，进程和程序间的区别是微妙的。用一个比喻可以使更容易理解这一点。想像一位有一手好厨艺的计算机科学家正在为他的女儿烘制生日蛋糕。他有做生日蛋糕的食谱，上面列出了所需的原料：面粉、鸡蛋、糖等，还有一个详细的做蛋糕的步骤。在这个比喻中，做蛋糕的食谱就是程序（即用适当形式描述的算法），计算机科学家就是处理器（CPU），而做蛋糕的各种原料就是输入数据。进程就是厨师阅读食谱取来各种原料以及烘制蛋糕等一系列动作的总和。这里的关键思想是：一个进程是某种类型的一个活动，它有程序、输入、输出以及状态。单个处理器可以被若干进程共享，它使用某种调度算法决定何时暂停一个进程，并转而为另一

个进程提供服务^[1]。

在面向进程而设计的系统中，进程是程序的基本执行实体；在面向线程设计的系统中，进程本身不是基本运行单位，而是线程的容器。进程可以分为系统进程和用户进程。凡是用于完成操作系统的各种功能的进程就是系统进程，它们就是处于运行状态下的操作系统本身。用户进程是由用户自己启动的进程。进程是操作系统进行资源分配的单位。在操作系统的设计中引入进程概念，可以方便地实现各任务之间的彼此隔离。系统中的每个进程都运行在自己独立的虚拟地址空间中，因此每个进程都认为自己是系统中唯一在运行的程序，并且拥有全部的系统资源，如 CPU、内存等^[2, 3]。

一个程序如果要运行，首先要由操作系统把它加载到物理内存当中。在程序加载的时候，操作系统负责将该进程的虚拟地址空间映射到物理内存当中。虚拟内存地址与物理内存地址之间的映射关系会被保存到页表（page table）中。操作系统负责进程之间的保护（也就是隔离），确保任何进程不能随意访问其它进程的地址空间。逻辑地看，每个进程的私有虚拟地址空间都被划分为代码段、数据段、堆栈段、以及进程状态段等若干部分，如图 2-2所示。

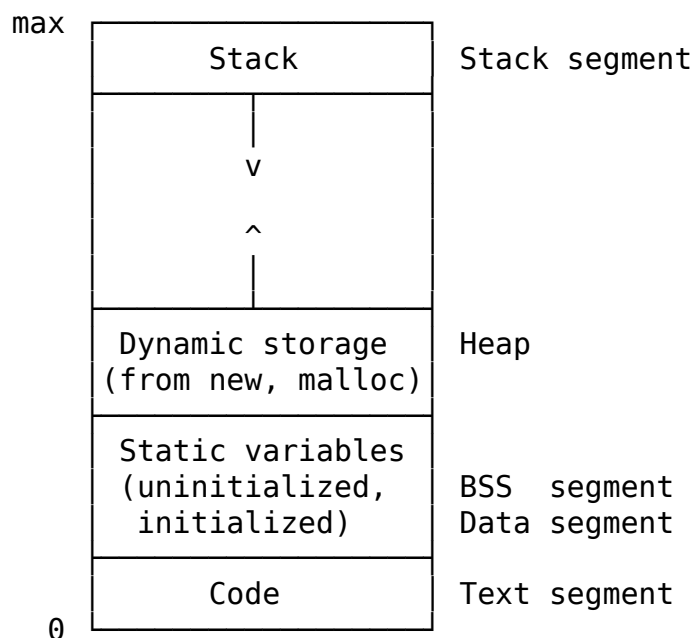


图 2-2 进程的逻辑结构
Figure 2-2 Process logical view

2.2.1 进程的地址空间

虚拟地址空间，或者也叫地址空间，是操作系统所能提供给进程的虚拟地址的范围^[4]。每个进程的虚拟地址空间的大小都与 CPU 所能寻址的最大空间相当。以 32 位系统为例，每个进程的虚拟地址空间大小为 $2^{32} = 4G$ 。4G 空间被分成两部分，高位部分地址用于映射操作系统的内核空间，低位部分地址用于用户空间的数据和代码映射。传统的 Linux 系统一般将进程的虚拟地址空间划分为 1G:3G，其中 1G 做为内核空间映射，3G 用做用户空间^[3]。本实验系统采用的是 2G:2G 的划分，即从 0~2G 的地址是用户空间，2G~4G 为内核空间。进程的虚拟地址空间如图 2-3 所示。之所以采用 2G:2G 的划分，是因为考虑到本文是以探讨内核开发为主，理应为内核留出更为充裕的空间。




图 2-3 进程虚拟地址空间
Figure 2-3 Process virtual memory space

在现代流行的操作系统的设计中，通常都是把内核工作空间完整地映射到每个进程的虚拟地址空间里^[5]。这样做的好处是，进程在请求内核服务时（如 system call 的调用），内核代码直接运行在当前进程的地址空间之内，不需要进行进程的切换，不需要改换地址空间，节省了很多的上下文切换的时间，只需切换到内核

模式即可运行内核代码。

2.2.2 进程状态与进程控制块

进程控制块 (Process Control Block) 也叫任务控制块, 是为了方便管理进程而在系统内定义的一个数据结构, 用来存放进程相关的各种信息, 包括进程所占用的内存大小信息, 页表信息, 状态信息, 进程身份 ID, 进程名称, 当前工作目录, 以及进程打开的所有文件文件等信息。系统对进程的操作都是通过对进程控制块的读写来完成的^[6]。其中, 进程的状态包括:

embryo: 是进程刚被创建时的状态。

runnable: 是指进程已经处于具备了一切可运行的条件的状态。

running: 是指进程正在运行的状态。

sleeping: 是指进程因为等待某种条件或事件而放弃 CPU 使用权而进入的睡眠状态。

zombie: 是指进程已经运行结束了, 但是所占资源尚未被完全回收时的状态。

以上各进程状态之间的转化关系如图 2-4所示。

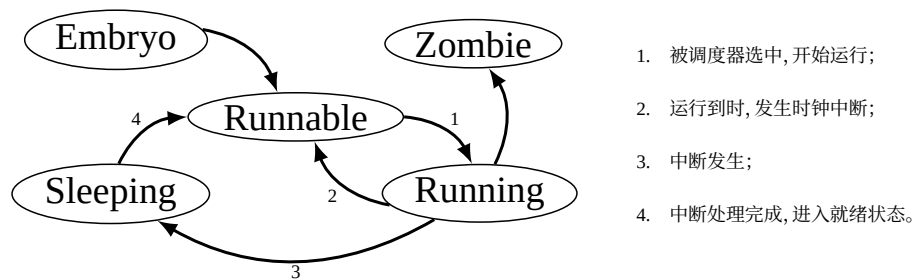


图 2-4 进程各状态之间的转化关系
Figure 2-4 Process state transition

在本项目中, 进程控制块被定义为一个结构体 (struct), 名为 `proc`, 其内容如程序 2-1所示。

为了便于统一管理系统中存在的所有进程, 创建一个 `proc[64]` 数组, 用来存放所有的进程。`proc[64]` 数组是所有的 CPU 所共享的。为了防止两个或多个 CPU 因同时访问它而引起冲突, 在这里我采取了给 `proc[]` 数组加锁的方法, 于


```

1 struct proc {
2     uint sz;                // 进程空间大小
3     pde_t* pgdir;          // 页表起始地址
4     char *kstack;          // 内核栈起始地址
5     enum procstate state;   // 进程的六种可能状态
6     int pid;               // 进程号
7     struct trapframe *tf;   // 位于内核栈中，用来保存 trap 发
    ↪ 生时的寄存器的值
8     struct context *context; // 指向进程的上下文
9     void *chan;            // 如果非 0，则进程位于 sleeping
    ↪ 队列里
10    struct file *ofile[NOFILE]; // 进程打开的文件
11 };

```

程序 2-1 proc 结构体

Code 2-1 struct proc

```


1 struct {
2     struct spinlock lock; //用于保护 proc 数组的锁
3     struct proc proc[NPROC];
4 } ptable;

```

程序 2-2 ptable 结构体

Code 2-2 struct ptable

是就定义了一个叫 ptable 的结构体，如程序 2-2所示。ptable、proc[] 数组、与 proc 结构体三者之间的关系如图 2-5所示。

图 2-5 ptable, proc[] 数组，与 proc 结构体
Figure 2-5 ptable, proc[], and struct proc

由于 ptable 是多进程都可以同时访问的公共数据块，这意味着若干进程有

可能同时读写该结构体。为了避免同时读写而发生的冲突，就需要引入一个加锁保护机制。进程只有在取得锁之后才能读写该公共结构体。关于加锁机制的实现，在后面的第 2.6.1 节有详细讨论。

2.2.3 内核栈

进程运行在用户态的时候，函数调用使用的是用户栈 (user stack)。当进程进入内核态运行的时候，如果还继续使用用户栈的话，就会降低系统的安全性。因为，在栈顶处存放的数据未必是合法的，有可能是用户进程产生的非正确的数据，甚至有可能遇上恶意进程存放的非法地址，如别的进程的地址，专门诱导内核为它做非法访问。为了避免这些危险，进入内核态运行时必须要有专门的内核栈 (kernel stack) 以供函数调用时使用^[7]。进程在内核态与用户态之间切换时，必须进行栈的切换。进程在新创建时，由 `allocproc()` 函数 (附录 A.1.2) 为其分配一个内核栈。内核栈主要用来存放 `trapframe` 和进程的上下文 (context)。其中，`trapframe` (附录 A.1.1) 是在系统响应中断时，内核栈中专门用来保护现场 (即保存相关寄存器) 时用的的一块区域^[8]。`context` 则是进程切换时，内核栈中专门用来存放与进程的上下文相关的寄存器的一块区域。

2.3 进程的创建与运行

创建一个进程，要先明确一个进程由哪些部分组成。这就如同要定义一个类 (class)，得先搞清楚它具有哪些属性，以及相对应的操作等。对进程的创建也是如此。程序要变成一个进程，不仅要被加载入物理内存，还要被分配一个全局唯一的身份号 (PID)，还要有名称，工作目录，以及运行、睡眠、退出等等一系列的属性和状态。于是，可以抽象地把进程定义为一个具有以上所述属性的 `proc` 数据结构。`proc` 的具体定义参见第 2.2.2 节中所述的 `proc` 结构体。

由于每个进程的虚拟地址空间里都包含了对内核空间的映射，为了安全起见，防止恶意进程在用户栈内设置非法地址，所以当进程进入内核模式运行时，必须另外有一个内核栈，供函数进入内核模式时使用而不是继续使用用户栈。于是，在创

建进程的时候，得首先给它从 `ptable` 里申请到一个空的 `proc` 结构体，然后为其创建一个内核栈。在本项目里，这两个工作是通过 `allocproc()` 函数（附录 A.1.2）来完成的。`allocproc()` 的主要工作流程如下：

1. 从头开始遍历 `ptable` 中的 `proc[]` 数组，从中找到的第一个进程状态为 `unused` 的数组单元即为可用单元；
2. 把找到的空单元格的进程状态设置为 `embryo`，表示初步占用；
3. 为新进程分配一个进程号；
4. 为新进程分配一个内核栈；
5. 在内核栈里预留一片 `trapframe` 大小的空间供 `trap` 发生时保存寄存器用；
6. 为 `trap` 的返回值预留一定空间；
7. 为保存进程上下文（`context`）预留一定空间；
8. 设置上下文内的 `eip` 指针让其指向 `fork()` 函数的返回处。

2.3.1 `fork()` 函数

在创建进程的时候，我采用的是用已有的进程创建新进程的方法，即母进程通过调用 `fork()` 函数来创建子进程。由于系统里的第一个进程（`initcode`）没有母进程，所以是由内核自己创建的，后来的进程都是由母进程通过调用 `fork()` 函数来创建。其中，调用 `fork()` 的进程为母进程，用 `fork()` 创建的进程为子进程。并且子进程在被创建时，复制了母进程的地址空间、进程状态、和打开的文件等内容。子进程创建完毕后，母进程继续完成它剩下的工作，而子进程则按照被创建的需求完成相应的工作。由于 `initcode` 是系统里的第一个进程，所以它可以被看成是其他所有进程的“始祖”进程。`fork()` 函数（附录 A.1.3）的工作流程如下：

1. 调用 `allocproc()` 函数为子进程申请到一个 `proc` 结构体并分配一个内核栈；
2. 为子进程分配页表并映射内核空间；
3. 将母进程的用户地址空间重复映射到子进程的页表中；
4. 复制母进程的进程状态给子进程；

5. 把母进程的内核栈里的内容复制到子进程内核栈内;
6. 把子进程中 `trapframe` 里 `fork()` 函数的返回值置为 0;
7. 把母进程打开的文件列表复制一份给子进程;
8. 把子进程的运行状态改为就绪 (`runnable`);

2.3.2 创建系统中的第一个进程

系统里第一个进程是 `initcode` 进程, 它是由内核直接创建的, 主要负责启动命令行 (`shell`)。由于它没有母进程, 自然不能通过调用 `fork()` 函数来创建, 因此也就没有母进程的 `trapframe` 和上下文 (`context`) 可供复制。所以, 内核要对系统中第一个进程的创建做特殊处理, 单独给它设置好内核栈里的 `trapframe` 和上下文 (`context`)^[9]。`initcode` 进程的创建工作是通过调用 `userinit()` 函数来完成的。在内核的主函数 (`main()`) 完成对硬件的初始化工作后调用 `userinit()` 函数来创建第一个进程。`userinit()` 函数所需完成的工作主要包括:

1. 调用 `allocproc()` 函数为新进程在 `ptable` 中的 `proc[]` 数组里分配一个空的数组单元, 为其分配一个内核栈, 并设置好进程的状态信息;
2. 调用 `setupkvm()` 函数为进程创建页表并映射内核空间;
3. 调用 `inituvm()` 函数为进程分配一页物理空间并把进程的二进制代码文件复制到这个空间里;
4. 设置进程的 `trapframe` 里的段寄存器的值;
5. 设置栈顶指针指向进程地址空间的最大值处 (即用户栈处);
6. 设置指令指针指向地址 0 处 (二进制代码的开始处);
7. 设置进程的名称为 `initcode`;
8. 把进程的运行状态从 `embryo` 改为 `runnable`;

在 `userinit()` 函数完成 `initcode` 进程的创建并把它置为 `runnable` 之后, 该进程就进入了系统调度队列, 可以接受调度运行了。

2.4 进程调度与算法实现

现代操作系统的重要特征就是支持多任务 即在系统内“同时”运行多个进程。所谓的“同时”，在这里应被理解为时分复用。一个 CPU 在任何时刻下只能运行系统里的某一个进程。但是，系统里却存在多个要执行的任务，为了解决这个问题，目前最常用的解决方案就是把 CPU 分时使用，即多个进程分时轮流占用 CPU。比如一个进程占用 10ms 之后，换成另外一个进程执行 10ms，然后再换成别的进程执行 10ms，...，其中每个进程一次能占用 CPU 的时长就称为时间片 (Time quantum)，这就是所谓的多任务并行。对于如何在多个任务中分配 CPU 的使用权，就需要制定一套相应的调度策略，也就是调度算法。调度算法的设计需要考虑的问题有：系统的吞吐率、响应时间、最低延迟、和最大化公平^[10]。在实践中，这些目标经常是互相冲突的，因此，调度策略需要实现一个权衡利弊的折中方案，而侧重点则可能是前文提到的任何一种，这取决于用户的需求和目的。

2.4.1 调度算法

调度算法设计的基本原则是避免进程“饥饿”，也就是让所有进程都有使用资源的机会，并保证使用资源多方的公平性。调度策略需要解决在大量请求下如何分配资源的难题。调度算法种类很多，最常使用的几种主要有：先入先出 (FIFO)、最短进程优先 (SJF)、时间片轮转法 (RR) 和基于优先级的 (OPT) 算法。这几种算法各有优点，同时也各有不足。例如 FIFO 算法，虽然实现起来简单，但是，如果遇到一大堆短进程出现在长进程的后面的情况的话，就会导致进程的平均等待时间过长。而 OPT 算法则容易出现进程饥饿的情况，即就绪队列里那些优先级较低的进程可能一直没有机会执行。时间片轮转 (RR) 算法设计简单，执行有效，又能实现公平性，所以使用广泛，所以，在本项目里我采用的是这种调度算法。

2.4.1.1 时间片轮转法 (RR)

RR 算法的主要思想是，规定一个定长的时间片，就绪队列里的进程按照先后来到的顺序轮流使用 CPU，在时间片用完时，不管进程是否已经执行完了，都得

```
1 struct context {  
2     uint edi;  
3     uint esi;  
4     uint ebx;  
5     uint ebp;  
6     uint eip;  
7 }
```

程序 2-3 context 结构体
Code 2-3 struct context

把 CPU 使用权让出给下一个进程。下一个进程同样是占用 CPU 达一个时间片长，然后再让出 CPU 给下一个进程，如此循环往复。此算法的特点是：算法的实用性取决于时间片的长度，如果时间片定义得太长，则会延长系统对进程的响应时间，甚至变回先来先服务算法；而如果把时间片定义得太短的话，虽然提高了系统对进程的响应时间却会导致频繁切换进程，从而增加系统的开销，因为系统每次进行进程的切换，都要在切换上下文上花掉一部分时间，降低 CPU 的使用效率。因此时间片的定义既不能太长也不能太短。在本项目中，时间片的大小定为 10ms。

2.4.2 进程切换的实现

进程的切换是指操作系统系统暂停当前占用 CPU 的进程，利用调度算法从就绪队列里选择另外一个符合条件的正在等待的进程，并把 CPU 交给它使用。进程切换机制使得共存于内存中的多个进程能共享 CPU，是操作系统实行多任务的手段。进程切换包括保存当前运行进程的上下文，选择下一个进程，切换页表，加载新进程的上下文等几个步骤。

2.4.2.1 进程的上下文

进程的上下文 (context) 是进程运行状态的静态描述 (快照)。具体地说，进程上下文包括计算机系统中与执行该进程有关的各种寄存器 (例如通用寄存器，程序计数器等) 的值^[11]。本实验中进程上下文 (context) 的定义如程序 2-3 所示。

2.4.2.2 进程的切换

由于系统中 CPU 的数量（通常只有一个）少于进程的数量，所以为了保证所有进程都能使用到 CPU，就要进行进程的切换。进程的切换就是进程的上下文切换（context switch）。在三种情况下需要进行进程的切换^[3]：

1. 进程运行完毕；
2. 进程阻塞；
3. 时间片用完。

进程在切换时，如图 2-6所示，显然必须要让出 CPU 的使用权。其中，第一种和第二种情况都属于进程主动放弃 CPU 使用权，而第三种情况属于进程不得不放弃 CPU 使用权。

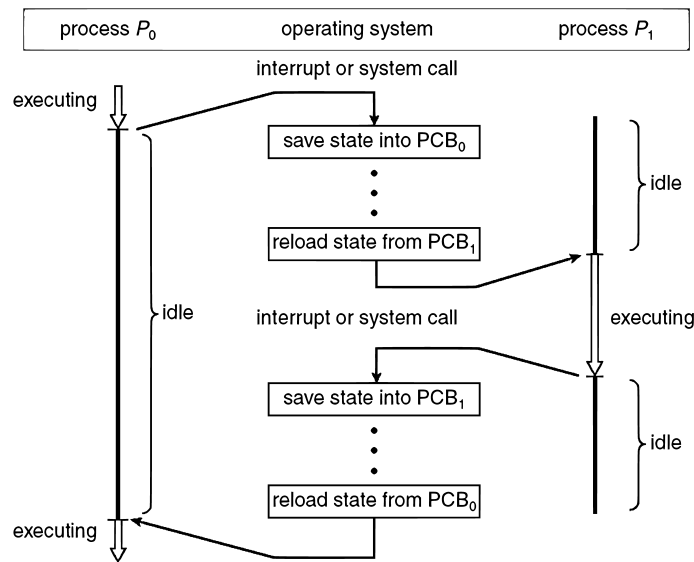


图 2-6 进程的切换过程
Figure 2-6 Process context switch

进程切换时不仅需要切换跟进程相关的整套资源信息，包括地址空间的切换和上下文的切换，还需要运行调度程序。其中地址空间的切换是通过改变页目录表（page directory）来实现的，而上下文的切换则是通过保存当前进程的寄存器的值和恢复新进程的寄存器的值来实现的。本设计中，进程切换的大致过程如下：

1. 当前进程如果工作在用户态则先切换入内核态；
2. 当前进程保存 eip, eax, edx 寄存器的值；
3. 当前进程把参数（当前进程的上下文和将要运行的进程的上下文）压栈；

4. 当前进程调用上下文切换函数 `swtch()`;
5. `swtch()` 函数继续把当前进程的寄存器压栈保存;
6. 切换到将要运行进程的内核栈;
7. 弹出将要运行进程的上下文寄存器的值;
8. `swtch()` 函数返回。

其中, `swtch()` 函数(附录 A.1.4)的工作内容主要是,把当前进程的上下文中用到的寄存器的值保存起来,然后切换到下一个要运行的进程的内核栈,再把该内核栈中进程上下文里的寄存器弹出就可以返回了。

2.4.3 调度算法的实现

本实验采用的调度算法是时间片轮转 (RR) 算法,其设计的主要思想是:从就绪队列的开头开始往下寻找第一个进程状态为 `runnable` 的进程,找到后把 CPU 使用权交给该进程。在下一次调度的时候便从该进程的位置开始往下寻找下一个 `runnable` 的进程……如此下去,如果搜索到了就绪队列的最后一个位置仍然没有找到一个 `runnable` 的进程后便回到队列的开头,从头开始搜索。

调度函数 (`scheduler()`) 也叫调度器,其主要工作是,

1. 按照规定好的调度算法来寻找下一个状态为 `runnable` 的进程;
2. 找到后,便把该进程设置为 CPU 的当前进程;
3. 调用 `switchvm()` 函数切换到该进程的虚拟地址空间;
4. 把当前进程的状态改为 `running`;
5. 调用 `swtch()` 函数切换到该进程的上下文后进程便可开始运行了。

值得一提的是,调度器自始至终都没有运行结束返回,实际上在内核启动时完成了对 CPU 的初始化工作之后,调度器就启动了。调度器运行起来后,本身就是一个内核进程,而且拥有自己的栈,这使得当前进程在让出 CPU 使用权时,实际上是先通过上下文切换到 Scheduler 进程的上下文,并把 CPU 使用权交给它。Scheduler 进程拿到 CPU 使用权后便开始了寻找下一个符合运行条件的进程,然后进行上下文切换,把 CPU 使用权交给该进程。在本项目里,调度器的实现是通过 (`scheduler()`) 函数(附录 A.1.5)来完成的。在进程切换的整个过程中,当前

进程 (A)、scheduler 进程、和下一个进程 (B)，这三者间的关系如图 2-7所示。




图 2-7 进程切换
Figure 2-7 Process switch

2.5 进程的退出

一个进程在创建后便开始运行，以完成自己的使命。然而，没有什么是永恒的，哪怕是一个进程也不例外。久而久之，进程终会终结退出。一个进程退出的原因主要有如下三个方面：

- 运行结束的正常退出；
- 运行过程出错而退出；
- 被另外的一个进程杀死而被迫退出。

当一个进程运行结束时，它并不能立即从系统中消失。事实上，在一个进程调用 `exit()` 函数退出时，它先转入 `zombie` 状态，直到其母进程为其释放了进程空间，以及回收其占用的进程控制块数据结构 (`proc`) 后才算真正退出。如果进程的母进程在其退出之前已经先行退出了的话，则由超级母进程 (`initcode`) 负责释放和回收其占用的空间^[12]。进程在彻底退出系统前需要完成一系列的退出准备工作^[13]，如：

1. 关闭该进程打开的所有文件；
2. 唤醒正在等待的母进程；
3. 把那些尚未运行结束或者已运行结束但不愿意为其完成资源回收工作的子进程交给 `initcode` 进程处理；
4. 把进程自己的状态设置为 `zombie` 态；
5. 把 CPU 使用权交给 Scheduler 以调度下一个进程。

当进程通过 `exit()` 函数（附录 A.1.6）把正在等待的母进程唤醒后，母进程的状态便重新变为 `runnable` 态，不久后将会被调度器选中。当母进程再次得到调度并运行起来后，会执行 `wait()` 函数（附录 A.1.7）来回收子进程所占用的资源。其主要的工作过程是：遍历 `ptable` 中的 `proc[]` 数组，寻找一个母进程为当前进程的进程，

- 如果找到了，则查看其状态是否为 `zombie` 态，
 - 如果是，则记录其进程号 (`pid`)；释放其内核栈及其整个地址空间；然后再将其所占用的 `proc` 结构体清空；将其进程号返回给系统；
 - 如果不是，则说明此进程尚未运行结束。跳过它，继续向下寻找。
- 如果没有找到任何一个子进程，则返回-1；
- 如果找到一个或若干个子进程，但都尚未运行结束，则让当前进程进入睡眠状态，以等待其中一个子进程运行完毕后将其唤醒。

在进程退出的整个过程中，`exit()` 函数所能做的工作只是释放进程所占用的文件资源，即关闭所有打开的文件。而进程所占用的其他资源，如内核栈、地址空间、进程控制块（`proc` 结构体）等的释放工作都是由 `wait()` 来完成。所以一个已经退出，却还没有被 `wait()` 的进程，虽然不再占用 CPU 资源了，但其实体仍然存在系统中，所占用的内存资源也没有得到释放。处于这种状态下的进程就是 `zombie` 进程。`zombie` 进程只有被母进程或 `initcode` 进程 `wait()`，才会完全退出系统，它所占用的资源也才能被重复利用。为了进一步说明这一点，这里将通过一个小程序 `testproc.c`（附录 A.1.8）来验证说明。程序主要以 `proc` 结构体这一个资源来进行实验。在本实验中，`proc[]` 数组的最大容量被设置成 64，即任意时刻，系统里最多可存在 64 个进程。`testproc.c` 所做的工作如下：

1. 母进程试图通过创建 100 个子进程来占满整个 `proc[]` 数组；
2. 在 `proc[]` 数组被占满后，系统将无法继续创建新进程；
3. 接下来，子进程纷纷运行结束，调用 `exit()` 函数退出；
4. 在子进程退出后，母进程试图再建新的进程；
5. 母进程调用 `wait()` 函数；
6. 母进程再次尝试创建新的进程；

7. 最后母进程退出，并把未 `wait()` 的子进程交给 `initcode` 处理。

本实验的测试结果在附录 A.1.8.1 中。由于 `testproc.c` 程序创建了多个进程进行测试，导致输出结果比较多。为了便于阅读分析，相似的大部分输出结果均以省略号 (...) 代替。

2.5.1 `testproc.c` 程序输出结果分析

虽然母进程试图创建 100 个子进程，但是由于进程控制块数组 `proc[]` 的最大容量是 64 个进程，所以当母进程创建了 61 个子进程后，`proc[]` 数组已经被占满，`allocproc()` 函数已经无法为创建新进程找到一个空闲 (`unused`) 的 `proc[]` 数组单元了，另外三个进程分别是 `initcode` 进程、`shell` 进程、和母进程 (`testproc`)。所以，母进程在创建完第 61 个子进程后便被迫退出创建子进程的循环体。接下来，所有的子进程都陆续运行结束并调用 `exit()` 退出。在所有的子进程都退出之后，母进程试图再次创建一个新的进程，却无法成功，因为，所有退出的进程都尚未被母进程等待 (`wait()`)，其所占用的 `proc` 结构体仍然没有得到释放，创建新进程的行为当然是不会成功的了。接下来，母进程调用了 31 次 `wait()` 函数来为 4~35 号子进程进行资源回收。在完成这一步回收工作后，`proc[]` 数组内已经有了多个空闲的 (`unused`) 单元，此时母进程再次试图创建一个新进程，于是便有了一个 65 号的新进程。母进程在做完以上这些工作后，发现自己已经很累了，不想再为剩下的 ($30+1=31$) 个子进程进行资源回收了，于是，它调用了 `exit()` 函数进行退出并把这 31 个子进程交给 `initcode` 进程进行资源回收，`initcode` 进程每为一个进程 (非 `shell`) 进行资源回收，都向控制台输出一个 “zombie” 表明它刚刚为一个 “继子进程” 进行资源回收，因为从严格意义上讲，只有 `shell` 进程是 `initcode` 进程的子进程。

2.6 进程间同步的设计与实现

现代操作系统的主要特点是支持多任务，多个进程共享 CPU、内存、硬盘等一系列系统资源。每个进程都有自己的地址空间，进程大多数时候也只访问自己

的地址空间里的数据。但是在有些情况下，相互协作的进程便需要共享对某些相关的共享数据的使用（读或写），例如共享某块内存区域，某个打开的文件，或者某个共享变量等。在访问共享数据时，如果碰巧出现一个进程在写，而另一个进程在读的情况，这时候如果写的进程恰巧比读的进程稍微慢一点点的话，那么进行读操作的进程将会漏掉“写进程”对于数据的更新。又或者，如果出现两个，甚至多个进程几乎同时要对某个共享数据进行写操作时，那么后一个进程的写入将可能会覆盖掉前一个进程的写入，导致只有最后一个进程的写入被保存了下来。这种由于多个进程同时访问同一个共享数据而产生冲突，叫作竞争（Race condition）^[14]。竞争在多任务系统里是比较常见的一个问题，即使是在单 CPU 的系统里也不例外。如当一个进程正在对共享数据进行写操作时，却遇上进程切换或者遇上中断的情况，这时候别的进程的就有可能漏掉这个进程对写的更新。竞争显然是需要被避免的，但是由于其出现未必有规律性，且经常依赖于严格的时间精度，因此要通过测试来发现竞争的存在就比较困难。因此，如何避免出现竞争便成了进程间同步要解决的难题。

竞争出现的原因主要是由于多个进程同时访问了共享资源。所以，寻找解决竞争的方法也主要是从如何阻止两个或多个进程同时访问同一个共享资源这一点出发。换句话说就是，需要实现互斥访问（mutual exclusion），即确保在一个进程对共享数据进行读写时，禁止别的进程访问这一个数据。

关于如何避免竞争出现的难题也可以用一种抽象的方式来描述。进程很多时候都是在做自己内部的事情或者别的不会引起竞争的一些事情，但有些时候进程又会执行访问共享数据的指令，或做一些可能会引起竞争的操作。我们把需要对共享资源进行访问的那一小段代码抽象叫做临界区域（Critical Region）或者临界区^[15]。因此，如果能采取有效的措施防止两个进程同时处于临界区内的话，就能避免竞争的出现。所以当进程正在使用临界区域的时候，别的进程必须等待其退出该区域后才能进入。然而，如果仅仅是做到了防止两个进程同时处于临界区内的这一步的话，也无法满足现代操作系统的要求的。现代操作系统要求实现多进程并行，所以不能因共享区域的互斥访问而使别的进程进入长时间甚至无限的等待中。换句话说就是，还必须做到进程处于临界区域的时间必须是短暂的，不能

太长。概括地说，如何高效率地解决竞争条件的出现需要满足以下几个条件^[16]：

- 任何两个进程不能同时处于临界区域内；
- 不对 CPU 的数量和速度做任何假设；
- 临界区域外运行的进程不能引起其他进程的阻塞；
- 不能是进程无限期等待进入临界区域。

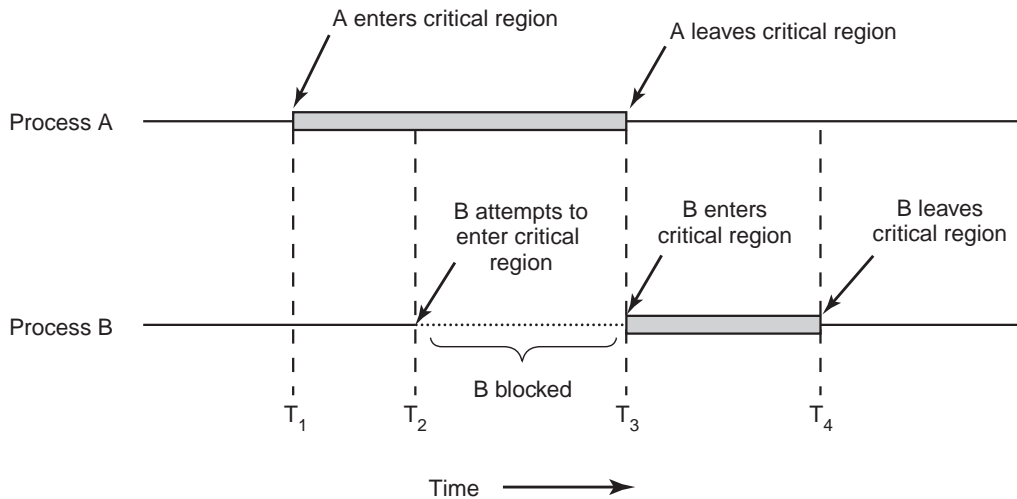


图 2-8 临界区域与竞争
Figure 2-8 Critical region

在图 2-8^[17] 所示的例子中，进程 A 在 T_1 时刻进入了临界区域，片刻之后，在 T_2 时刻进程 B 也运行到了临界区域，但因为此时已经有一个进程处于临界区域内了，即进程 A，根据互斥法则，进程 B 将无法成功进入临界区域，此时，进程 B 将会被处于等待进程 A 的临界区域退出中。之后不久，在 T_3 时刻，进程 A 完成了对临界区域的操作并且退出，此时，进程 B 便能立刻进入临界区，最后，进程 B 在 T_4 时刻也完成了对临界区的操作，此时，系统回到了没有进程处于临界区内的状态了。

2.6.1 锁机制的实现

实现临界区域互斥访问的一个比较常用的有效方法是锁机制。锁机制的原理是，给每一个共享数据分配一个锁变量，这个锁变量在任意一时刻只能最多被一个进程所持有。任何进程在欲进入临界区域时，必须先通过检查锁变量的值（值为 0 表示可用，非 0 则表示不可用）来判断锁是否可用。如果检查到锁变量的值为

0，则立即把值更新为 1（非 0 值），以排斥其他进程的进入，然后进入临界区域，进程退出临界区域后便把该变量的值恢复回 0；如果检查到锁变量的值为非 0，则需等待其他进程把变量设置为 0 后方能进入。

上述锁机制存在着一个问题，如果有两个进程恰巧同时检测到锁变量的值为 0，于是两个进程都把该值变为非 0，于是这两个进程都进入了临界区，此时又产生了竞争，如程序 2-4 所示。

```

1  acquire(struct lock *lk){
2      for(;;){
3          if(!lk.locked) {
4              lk.locked=1; //这里将出现 Race condition
5              break;
6          }
7      }
8  }
```

程序 2-4 存在竞争
Code 2-4 Race condition exists

显然，问题出现的原因是由于进程获取锁这一个事情分成了两个步骤即查看变量值是否等于 0 和把值变为 0。所以，必须做到把这两个步骤合并为一个步骤，才能断绝出现一个进程正在更新变量的值的时候，另外一个进程溜了进来并也成功把变量值设置为非 0。如何把两个步骤合为一个步骤是通过一条特殊的 CPU 指令来实现的，那便是 `xchg` 指令。`xchg` 指令实际上就是把两个操作数的值对掉一下，最后返回旧操作数的值。使用 `xchg` 指令后，获取锁的过程便由程序 2-4 变成了程序 2-5。

```

1  acquire(struct lock *lk){
2      while(xchg(&lk->locked, 1) != 0);
3  }
```

程序 2-5 避免竞争
Code 2-5 Race condition avoided

在程序 2-4 中，如果两个进程同时运行到了第 3 行，都检测到 `lk.locked==0`，于是都迅速抓住了锁，便执行第 4 行，就造成了两个 CPU 都持有锁，这显然是与互斥原则想违背的。在程序 2-5 中，`xchg` 指令首先把 `lk.locked` 的值与 1 进行交

换，之后再返回 `lk.locked` 原来的值。如果 `lk.locked` 的值为 0，那么与 1 交换就直接相当于把它更新为 1 了，然后再返回一个 0 告知进程已成功获得锁。

2.6.2 死锁

死锁是指，组内的每个成员都一直处于等待状态，等待别的成员做出诸如发送消息或者释放锁的动作，以便能继续执行任务^[18]。死锁现象在那些利用锁来保护共享资源的系统里比较常见，如多进程系统、并行计算系统，和分布式系统里^[19]。举例来说，进程 1 和进程 2 都需要获取两个锁（A 和 B）才能继续工作。但是，进程 1 是以先 A 后 B 的顺序来获取这两个锁；而进程 2 却是以先 B 后 A 的顺序来获取这两个锁的。这时候就有可能出现，进程 1 获得 A 锁的同时进程 2 也获得了 B 锁，接下来，进程 1 便因等待 B 锁而被阻塞，而进程 2 也因等待 A 锁而被阻塞。两个进程都在等待对方释放所持有的资源，但双方却又都拥有对方所缺少的资源，于是谁也不能继续工作，也就无法释放所拥有的资源，只能无限期地等待下去，这种状态就叫死锁。为了防止出现这种情况，可以规定两个进程都按同一个顺序一一获取这些锁。防止出现死锁的主要方法还有关中断和禁止进程在持有锁的情况下被阻塞。其中关中断主要应用于进程持有 `spinlock` 的情况下，遇到了中断的到来，此时 CPU 不得不转入该中断处理程序运行，但不幸的是该中断处理程序又恰巧需要获取该 `spinlock`，于是中断处理程序必须等待进程释放它，但是该 `spinlock` 却无法被进程释放，因为进程必须得等到中断处理程序返回后才能继续运行，于是死锁就出现了。为防止出现这种死锁，就得在获取 `spinlock` 之前先关闭中断。另外一种情况，如果一个进程在持有锁的情况下被阻塞进入睡眠状态的话，那么别的需要这个锁的进程将会陷入无限期等待。所以，必须要求进程在进入睡眠等待前释放所持有的锁。

2.6.3 锁的种类

前面已经说过，进程在进入临界区域前必须先成功获得锁后方能对临界区域进行读写操作。如果一个进程在尝试获取锁的时候发现这个锁已经被别的进程持有了，那么这个进程接下来该怎么做？可以有两种处理方式：第一种是进程一直

```

1 struct spinlock {
2     uint locked; // 锁变量, 值为 0 表明可用, 值非 0 表示不可用;
3     struct cpu *cpu; // 持有该锁的 CPU; 为方便调试时用;
4 };

```

程序 2-6 spinlock 结构体
Code 2-6 struct spinlock

不断地尝试获取锁这个动作（即所谓的“忙等”，busy waiting）^[20]，直到持有该锁的进程释放该锁后，拿到锁，才能进入临界区；第二种是一旦发现锁不可用的情况下，立即自愿放弃 CPU 而进入睡眠状态，等待别的进程释放该锁后再唤醒它。显然采取忙等的情况会造成一定的 CPU 时间的浪费，尤其是锁被持有的时间比较长的话就更加浪费 CPU 时间了。然而，事实上，有些临界区域的操作时间事件上非常短，甚至短于进行进程切换所耗费的时间。这种时候采取忙等的方式来获取锁显然就是比较理想的了。前文所提到过的 spinlock 就是采取这种方法获取锁的。第二种处理方式则适合于获取那种需要长时间保持的锁，例如文件系统读写硬盘上的文件，这时候的硬盘操作需要的时间就比较长了，有时甚至需要持续几秒钟。如果继续用忙等的方式来获取锁的话，那将会造成大量的资源浪费，所以，应该以第二种方式获取。而且为了提高系统效率，现代操作系统都规定进程在读写硬盘的时候要让出 CPU。这个时候就需要一种进程能长时间持有的锁，甚至在进程被切换出去后仍能持有该锁并继续完成 I/O 工作，这种锁就是 sleeplock。spinlock 的具体定义的代码如程序 2-6 所示。

获取 spinlock 的过程中需要首先关闭中断，以防止进程在持有 spinlock 的情况下被中断信号打断从而可能引起的死锁问题。中断将在进程释放 spinlock 的时候开启。acquire() 函数的代码如程序 2-7 所示。

sleeplock 的定义如程序 2-8 所示。

由于获取 sleeplock 的过程需要分几步才能完成，只交换两个操作数值的 xchg 指令无法完成这工作，因此，为了防止两个进程同时获取 sleeplock 而产生竞争而把获取 sleeplock 的过程代码当成是临界区域，用一个 spinlock 保护起来。所有欲获取 sleeplock 的进程必须首先获得 spinlock。因此，获取 sleeplock 的过程主要分为三步：首先获取属于该 sleeplock 的 spinlock，在成功


```

1 void acquire(struct spinlock *lk) {
2     pushcli(); // 首先关中断以避免死锁;
3     if(holding(lk))
4         panic("acquire");
5
6     while(xchg(&lk->locked, 1) != 0);
7
8     lk->cpu = mycpu();
9 }

```

程序 2-7 acquire() 函数
Code 2-7 acquire() function

```

1 struct sleeplock {
2     uint locked; // 锁变量;
3     struct spinlock lk; // 用来保护 sleeplock, 以防出现死锁;
4     // 为方便调试:
5     char *name; // 锁的名称;
6     int pid; // 持有锁的进程;
7 };

```

程序 2-8 sleeplock 结构体
Code 2-8 struct sleeplock

获取 spinlock 后, 再查看 sleeplock 是否已经被别的进程占用, 如果已经被占用的话, 进程则以进入睡眠状态的方式来等待该 sleeplock, 当然, 为了防止出现死锁, 进程首先释放已取得的 spinlock 后方可进入睡眠状态。如果 sleeplock 没有被别的进程占用的话, 进程则可通过把 sleeplock 的锁变量值更新为 1 并且把 sleeplock 对应的进程设置为当前进程的方式来获取锁, 最后进程释放 spinlock。获取 sleeplock 的函数 acquiresleep() 的具体定义如程序 2-9 所示。

本文主要围绕进程管理和内存管理进行研究, 对文件系统部分涉及较少。所以, 此处探讨的重点是 spinlock 的使用, 而非 sleeplock。本文所讨论的 spinlock 主要用于保护进程表, 即 ptable 结构体里的 proc[] 数组, 和存放所有打开的文件的列表数组, 即 ftable 结构体里的 file[] 数组, 还有时钟变量 ticks。

以保护 ptable 的 spinlock 为例, ptable 里的 proc[] 数组记录的是系统内所有进程的各种状态信息, 每一次进程的创建、运行、切换、终结, 都要涉及 proc[] 数组内相应的数据的读写。其中, 进程在创建时, 需要在 proc[] 数组里找到一个空的位置, 然后把该位置设置为“已占用”。此时的操作必须是互斥的, 否

```

1  void
2  acquiresleep(struct sleeplock *lk)
3  {
4      acquire(&lk->lk);
5      while (lk->locked) {
6          sleep(lk, &lk->lk);
7      }
8      lk->locked = 1;
9      lk->pid = myproc()->pid;
10     release(&lk->lk);
11 }

```

程序 2-9 acquiresleep() 函数
Code 2-9 acquiresleep() function

则就有可能出现两个进程几乎同时扫描到同一个空位置，接下来便把它更新为已占用，这样的话，先动手的进程的更新便被后动手的进程的更新给覆盖了。同样，调度器在运行进程前需要把进程的状态改为 `running` 态，如果在调度器把进程从 `runnable` 状态改为 `running` 状态的过程中，另外一个 CPU 的调度器读到了该进程的状态为 `runnable`，于是，它也把该进程加载过去运行，此时就会出现一个进程同时被两个 CPU 重复运行的情况。所以，对这样一个所有 CPU，所有进程都共用的数据结构，必须要用一个锁保护起来。由于，进程对 `proc[]` 数组的读写都非常简单快捷，所以用一个 `spinlock` 就很合适。`ptable` 的定义，已在第 13 页给出，这里不再重复。

2.6.4 进程的阻塞与唤醒

一个进程在系统中存在的状态有四种(`runnable`, `running`, `zombie`, `sleeping`), 但任一时刻内，一个进程只能以其中一个状态存在。对于前面三种状态已经在前面讨论过了，现在要说的 `sleeping` 态，即阻塞态。阻塞态是指进程需要等待别的进程完成某件事情后方可继续执行。如等待一个正在被别的进程使用的公共资源的释放或者等待一个子进程的退出或者等待一个 I/O 操作的完成等事情^[21]。进程在等待时，与其在不停地主动查看所等待的事情是否已经完成，空浪费 CPU 的时间，不如主动进入睡眠状态，让出 CPU 使用权，在所等待的事情完成后由别的进程以通知的方式告知该进程，从而避免了忙等 (`busy waiting`) 所造成的资源浪费

的问题。进入睡眠状态的进程会被记录在一个睡眠链表中，当别的进程把该进程所等待的事情完成后，便给该链表发送一个信号，以唤醒该链表内所有在睡眠的进程，此时链表内所有符合条件的进程都由 `sleeping` 态转为 `runnable` 态。进程进入通过调用 `sleep()` 函数进入阻塞态，并由别的进程调用 `wakeup()` 函数唤醒。`sleep()` 函数基本思想是：把当前进程加入到睡眠队列 (`chan`) 内，然后把进程状态标志为 `sleeping` 态，最后调用 `sched()` 函数让出 CPU。`wakeup()` 函数从指定睡眠链表里把进程唤醒，把进程状态标志为 `runnable` 态。`sleep()` 和 `wakeup()` 可以使用任意的数据来区别不同的睡眠链表，只要 `sleep()` 和 `wakeup()` 能用同一个数据就行。当然使用跟等待有关的数据的则更明了。

`sleep()` 的主要工作过程如下。首先确保调用 `sleep()` 函数的是当前运行的进程，并且确保进程已经将所持有的锁 (`lock`) 传给 `sleep()` 函数了。这主要是进程在调用 `sleep()` 前总是已经持有某个 `lock`。如，`wait()` 在先取得 `ptable.lock` 后才能扫描 `proc[]` 数组找一个 `zombie` 的子进程为其释放资源，但是如果子进程均没有运行完毕的话，`wait()` 则需要等待其中一个进程运行终结。此时，`wait()` 便会调用 `sleep()` 并把 `ptable.lock` 传给它。这样 `sleep()` 函数在更新进程状态的时候就不需要再次获取该 `ptable.lock` 了。如果进程在调用 `sleep()` 前持有的锁不是 `ptable.lock` 的话，则需要先获取 `ptable.lock` 后再将该 `lock` 释放，这样方可避免出现别的进程在当前进程尚未完成进入 `sleep()` 的准备工作之前已经发送了一个唤醒信号而导致出现该信号被漏掉的 `lost-wakeup` 现象。接下来 `sleep()` 函数便把当前进程加入到指定的睡眠链表内并更新其状态为 `sleeping` 然后调用 `sched()` 让出 CPU。之后进程会一直处于 `sleeping` 态直到别的进程给它发送一个唤醒信号，并把它状态更新为 `runnable` 态后进程才能重新接受调度，在进程重新运行起来后，`sleep()` 便把进程从睡眠链表里撤出，并重新获取进程在调用 `sleep()` 前所持有的 `lock`。`sleep()` 函数的具体定义参见附录 A.1.9。

3 内存管理的设计与实现

内存管理从本质上来说就是一种资源管理，只不过在这里所要管理的对象是计算机系统里的内存（RAM）而已。内存是计算机系统里一个非常重要的资源，所有程序的运行都依赖于内存。虽然随着现代科技的迅猛发展，内存的尺寸也越大，但同时，系统对内存的需求也在飞速增长，而且增长的速度远远大于内存增长的速度^[22]。所以，如何在有限的内存空间里同时运行多个进程还一直是操作系统研发的重点。内存管理是操作系统里专门负责管理内存的一个模块，主要工作就是高效率地管理这个有限的内存空间，如，给进程分配运行空间、回收进程不再使用的空间、记录已使用的和未使用的内存区域等一系列事务。

3.1 总体设计模型

内存管理所需完成的工作主要有：如何为用户提供一个内存的抽象，如何管理组织系统内的空闲内存，如何尽可能地节约内存的分配，以及如何回收内存。本项目的内存管理功能模块如图 3-1所示。

分页机制是实现虚拟内存一种技术，主要是为用户进程提供一个对内存的抽象，它使得应用程序认为它拥有连续可用的内存（一个连续完整的地址空间）。而实际上，一个程序所使用的虚拟内存空间通常被分隔成多个逻辑部分，即所谓的“段”（segment），如代码段、数据段、堆、栈等等。在程序运行时，这些段会被加载到物理内存中。值得注意的是，程序运行时，操作系统并不需要把该程序完整地加载入物理内存。如果程序较大的话，通常操作系统只会把该程序中马上要用到的部分加载到物理内存中，也就是“按需加载”。那些暂时存储在外部磁盘存储器上的部分，会在需要时被加载入物理内存^[23]。与没有使用虚拟内存技术的系统




图 3-1 内存管理功能模块图
Figure 3-1 Memory management modules

相比，使用这种技术使得大型程序的编写变得更容易，首先程序员不需要担心程序大小是否已经超过物理内存的大小。其次，程序员在操作地址时也不需要担心这些地址是否会与别的程序使用的地址冲突，因为程序里出现的一切地址都会被系统当成虚拟（逻辑）地址进一步处理，而不是直接送往地址线上。负责处理逻辑地址的硬件功能模块是“内存管理单元”（MMU）。MMU 是 CPU 集成电路的一部分。CPU 给出的地址（逻辑地址）首先会送往 MMU 进行地址翻译，翻译完成后再送往地址线上^[24, 25]。

Freelist 是用来管理系统里的所有物理内存空闲页面所创建的一个链表。在给进程分配内存时是每次从该链表中拿出一页交给进程；回收内存的时候则是把不再使用的页面加入到该链表中。

Allocation 负责的是为进程分配内存，主要通过写时复制的方法来解决进程创建时的内存分配，以及如何为有需求的进程进行重新映射地址空间和如何处理进程运行时的内存分配。

Deallocation 这一部分实现的是如何为进程回收不再需要的内存资源，包括运行时的内存回收和运行结束后的内存回收。

3.2 详细设计与实现

内存管理主要是实现如何高效率的分配内存，如何回收内存，以及如何管理空闲内存。这一节将讨论如何实现这几个功能。

3.2.1 分页机制

虚拟内存概念引入的主要目的是为了防止程序直接访问物理内存和访问不属于自己的地址空间，所以虚拟内存的主要任务就是实现地址重定向和地址空间的保护。实现虚拟内存的技术主要有：分段技术和分页技术。

3.2.1.1 分段技术

分段技术出现得比分页技术早。分段技术的基本思想是：将程序所占用的内存分为若干段（segment），段的大小可以不一样，每个段有一个段号和一个表示段大小的 limit^[26]。如图 3-2 所示，当处理器要进行内存寻址时，所给出的地址就包含了段的号码，以及段内偏移量（offset）。系统根据地址里提供的段号（段选择子，segment selector）查询段描述符表（descriptor table）得到该段的基址（base address）再根据地址里所给出的偏移量找到 CPU 所要求的地址单元。

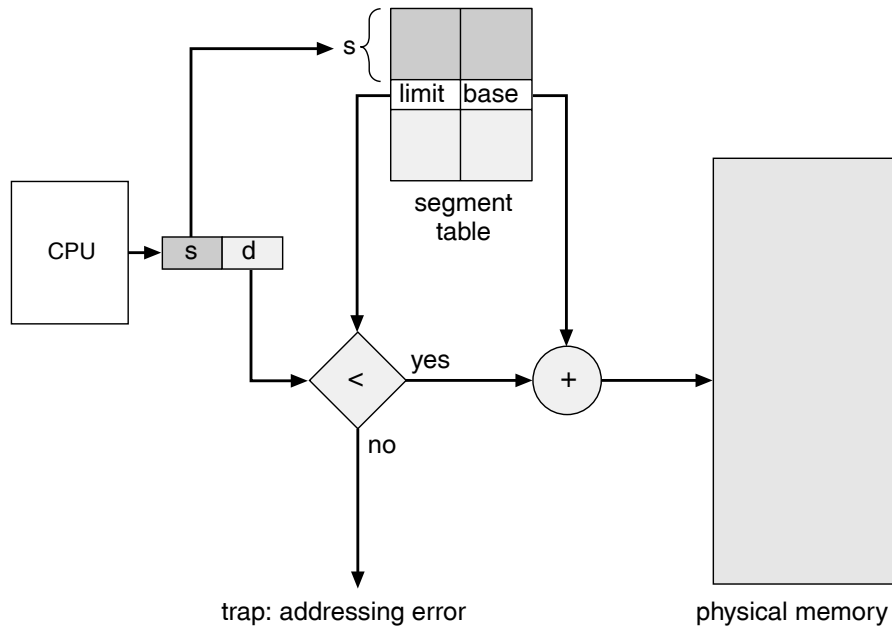


图 3-2 段式虚拟内存地址翻译过程

Figure 3-2 Address translation via segmentation

一个程序通常包含数据段，代码段，BSS 段、堆、和栈等若干部分。内核在把程序段加载进物理内存前，首先得在物理内存内为程序找到空的位置，然后再加载程序段。内核把程序段与所在的物理内存段的对应关系记录在一张表格中，这

张表就叫段描述符表 (Segment Descriptor Table)。CPU 在每次访问内存时, 内核会首先查询这张表以找到程序的段所在的内存段的入口地址, 然后再加上段内偏移量就得出一个物理地址, 送往地址总线^[27, 28]。如果地址里所给出的段内偏移量超出了该段的限制的话, 系统就会产生一个段错误 (segmentation fault) 通知内核, 内核便会终止该进程的运行。

分段技术实现了地址的重定向和地址空间的保护, 但却存在一些问题: 在系统运行的过程中, 由于不断会有新的进程被加载入内存, 同时也不断有进程运行结束, 释放内存, 而且进程所占用的内存段, 既不连续, 大小也不固定, 在系统运行一段时间后, 物理内存中的剩余空间会呈现“碎片化”现象, 即内存中会产生很多不连续, 且大小不等的剩余空间, 这就是所谓“外部碎片”。在这种情况下, 如果有一个新进程需要运行, 操作系统很可能无法从这些碎片中为其找出一个大小合适的空闲段来加载该进程。此时如果使用一个较大的段的话也会造成内存空间的浪费。

分页技术出现后, 分段技术的使用已经越来越少, 许多新推出的处理器甚至不再支持分段机制了。另一些系统同时支持分段和分页机制, 如 Intel 的奔腾处理器, CPU 给出的虚拟地址在送给 MMU 之后, 首先会经过分段模块的处理, 分段模块把虚拟地址翻译成线性地址后, 再交给分页模块进行最后的物理地址翻译 (如图 3-3 所示)。





图 3-3 Intel 奔腾处理器的地址翻译过程
Figure 3-3 Intel Pentium virtual address translation

Linux 系统主要依赖于分页技术, 而不用分段机制, 这一方面是因为分段与分页这两种虚拟内存技术功能大同小异, 采用其中一个就够了; 另一方面是因为很多硬件架构都放弃了分段技术。因此, Linux 为了达到跨平台的目的, 当然就要最大程度地绕开分段技术。通过把所有的段基址都设置为 0, 把所有的段限值 (limit) 都设置成 4G, Linux 成功省去了从逻辑地址到线性地址的翻译步骤^[29]。本实验里采用的就是 Linux 的这一个处理方法。

3.2.1.2 分页技术

分页技术的基本思想是把程序分成许多个大小相等的块，每一个块称做一页 (page)，每一页内的地址都是连续的。相应的，物理内存也被分割成许多个大小相等的块，这些块称做页框 (page frame，也叫物理内存页)，页框的大小跟页的大小一致。程序的页会被映射到物理内存中去，每一个虚拟页对应一个物理的页框，但并非所有的页都要加载进内存才能运行^[11]。描述页与页框之间的映射关系的表叫做页表 (page table)，每个进程都有自己独立的页表。在分页机制下，所有 CPU 给出的地址都被分成两部分：一个页号 (page number) 和一个页内偏移量 (page offset)，如图 3-4 所示。其中，页号是用来访问页表的下标。页表里给出了所有物理内存页框的基地址。



$$\text{page number} = 00000000000000000010 = 2, \quad \text{page offset} = 000000000100 = 4$$

图 3-4 页号与页内偏移量
Figure 3-4 Page number and page offset

CPU 给出的虚拟地址首先被送入 MMU 中，MMU 主要的工作是负责把该地址翻译成物理地址。MMU 首先从虚拟地址中提取出页号并以该页号为下标访问页表，得出该地址所在的物理内存页的起始地址，然后把该起始地址加上页内偏移量，就得出一个实际物理内存地址，把它送往地址总线，完成了一个虚拟地址的翻译。图 3-5 简单展示了一个 16 位线性地址经过分页处理（查询页表）被翻译成一个 15 位的物理地址的过程^[17]。分页机制通过地址映射，实现了虚拟内存的地址重定向。每个进程都有属于自己的页表，页表里只映射了属于进程自己内存空间里的地址，进程无法访问不在自己页表覆盖范围内的地址，由此实现了进程地址空间的保护。

不同的系统对页面的大小的规定不一样，但都是 2 的 n 次方，如 4kb、8kb、




图 3-5 分页地址翻译的过程

Figure 3-5 Virtual address translation via paging

4M 等，在 32 位系统里，采用的大都是 4kb 大小的页。由于页是内存分配的最小单位，在分配空间时，如果一个程序的大小没有刚好是页大小的整数倍的话，那么最后一个页面的空间就没有被完全利用，所浪费的空间就叫“内部碎片”。所以页面太大的选择就值得考虑。页面越大，内部碎片浪费的空间又会越大；页面越小，每个程序所需的页表数量又会越多，页表数量的增加会直接导致加载页表时花费的时间越多，于是最佳页面大小的选取必须在这几个因素间权衡。Intel 奔腾处理器可以支持 4K 和 4M 两种大小的页面，Sun 的 UltraSPARC 支持 8K、64K、512K、和 4M 大小的页面。用户可以根据需要，在编译内核时，选定某一大小的页面^[3]。通常，32 位系统大多采用 4kb 大小的页面。

3.2.1.3 页表结构

随着计算机科学技术的发展,现代处理器的寻址空间都达到了 32 位,甚至 64 位。在这种情况下,一个程序的虚拟地址空间可达 2^{32} 或 2^{64} 个字节的大小^[4]。以 32 位系统为例,如果每个页面的大小为 4k,页表中每条记录 (page entry) 的宽度为 4 字节,那么就需要 $2^{32}/4k = 1M$ 条记录才能覆盖 4G 的虚拟内存空间。于是,一个进程的页表本身就要占用 $1M \times 4 = 4M$ 的内存空间。为了存放这一个页表,就得在物理内存里找到一块 4M 大小的连续区域。如果系统内有 N 个进程,就要消耗掉 $4M \times N$ 大小的空间来专门存储页表,这个开销对系统来说显然是比较沉重的。解决这个问题一个有效的方法是对页表本身进行分页:将一个 4M 大的页表分成 1K 个 4K 大小的页表,这 1K 个页表可以独立存放于物理内存中。另外,系统再拿出一页来专门记录这 1K 个页表在物理内存中的具体位置,这一页就叫一级页表 (page directory),另外那 1K 个页表都是二级页表 (page table)。由于大部分程序都用不到整个 4G 地址空间,实际上,每个进程都只用到了地址空间内的少数几个集中的页面而已,于是在页面映射时,内核只需把用到的这些页面映射到物理内存上,而被映射的虚拟地址才需记录在二级页表内,此时二级页表的数量就可以根据实际需要来定了,如果只有 1K 个虚拟页需要映射到物理内存,那么系统只要花费一张二级页表就足够了。这种二级页表的方法无疑为系统节省了不少的开销。

一级页表里有 1k 条记录 (page directory entry, 简称 PDE), 每条 PDE 指向一个二级页表。对应的二级页表的记录叫 (page table entry, 简称 PTE)。PDE 与 PTE 的结构相似,都是高 20 位代表物理内存页的地址,低 12 位代表标志位。Intel 奔腾处理器所支持的 PTE 的结构如图 3-6所示。其中 PDE 与 PTE 的不同之处在于 D 标志位,该位置 0 则表示是 PDE。标志位的定义如程序 3-1所示。

在两级分页机制下,CPU 给出的虚拟地址被送入 MMU,MMU 先提取地址的最高 10 位 (图 3-7) 做为访问一级页表的下标,从一级页表内得出一个二级页表的地址,再提取接下来的 10 位地址作为访问该二级页表的下标,并从中得出 CPU 所要求的物理内存页的开始地址,然后再加上虚拟地址的最低 12 位偏移量即可得出一个完整的物理地址,并送往地址总线。两级分页的地址翻译过程如图 3-8所示。

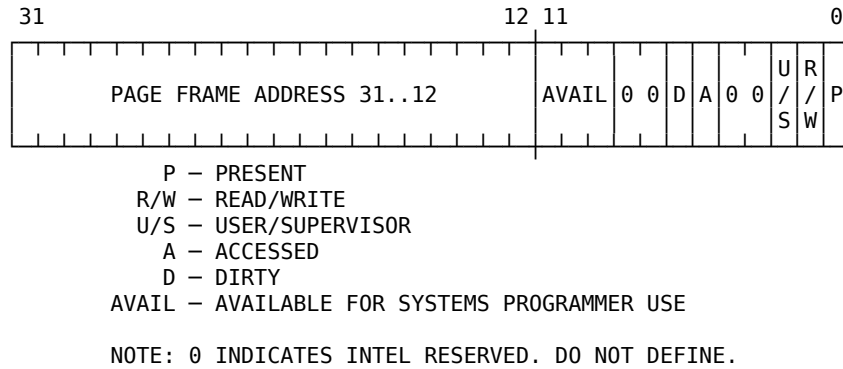


图 3-6 Intel i386 页表定义

Figure 3-6 Intel i386 Page Table Entry

```

1 #define PTE_P 0x001 //表明该页已经映射
2 #define PTE_W 0x002 //表明该页可写
3 #define PTE_U 0x004 //表明该页允许用户访问
4 #define PTE_A 0x020 //表明该页已经被访问过
5 #define PTE_D 0x040 //表明该页是二级页表

```

程序 3-1 PTE 标志位

Code 3-1 PTE flags




图 3-7 32 位线性地址两级分页

Figure 3-7 Two-level paging virtual address

3.2.2 页表的实现

页表的作用是负责记录虚拟地址到物理地址的映射关系。页表的设置主要完成的工作就是为每一页虚拟地址找到一个空闲的物理内存页，并把这一个物理内存页的开始地址记录在这个虚拟地址对应的页表项内，最后再把该页的标志位信息填入页表项内，便完成了一页虚拟地址到一页物理内存地址的映射关系的填写。本实验把完成页表设置的工作定义在名为 `mappages()` 的函数中（附录 A.2.1），其函数原型如程序 3-2 所示。

`mappages()` 函数需要的参数分别是：`pgdir`, `va`, `size`, `pa`, `perm`。其中，

- `pgdir` 指向将要设置的一级页表；

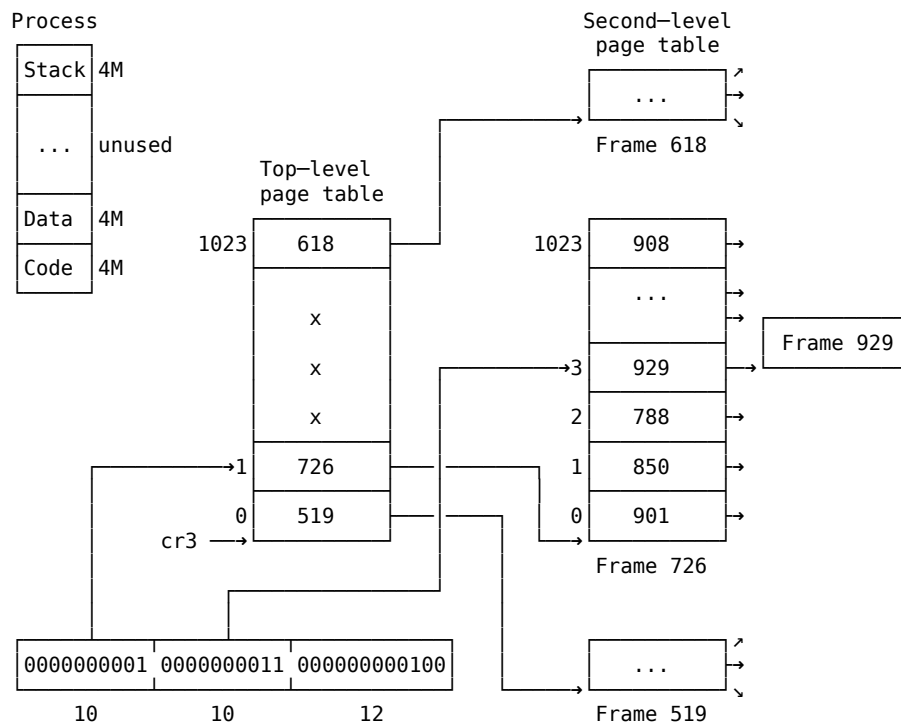


图 3-8 两级分页地址翻译过程

Figure 3-8 Two-level paging

```

1 static int
2 mappages(pde_t *pgdir, void *va, uint size, uint pa, int
   ↪ perm);

```

程序 3-2 mappages() 函数原型

Code 3-2 mappages() function prototype

- `va` 指向将要被映射的虚拟地址的开始处；
- `size` 代表需要映射的总共的虚拟地址大小；
- 而 `pa` 则指向要映射的物理地址的开始处；
- 最后一个参数 `perm` 指定该页是否允许用户访问或是否可写。

`mappages()` 函数的工作就是负责把从 `va` 开始到 `va+size` 的虚拟地址给一页一页地映射到物理内存的 `pa` 开始处，并按 `perm` 所指定的值把这每一页的第三个标志位进行设置。

`mappages()` 函数（附录 A.2.1）对二级页表进行设置的详细过程如下：

1. `mappages()` 函数首先把需要映射的虚拟地址 `va` 进行页对齐操作，得到 `va` 所在页的起始地址 `a`；

```

1  static pte_t *
2  walkpgdir(pde_t *pgdir, const void *va, int alloc)
3  {
4      pde_t *pde;
5      pte_t *pgtab;
6      pde = &pgdir[PDX(va)];
7      if(*pde & PTE_P){
8          pgtab = (pte_t*)P2V(PTE_ADDR(*pde));
9      }
10     else {
11         if(!alloc || (pgtab = (pte_t*)kalloc()) == 0)
12             return 0;
13         // 把新分配到的二级页表全部初始为 0;
14         memset(pgtab, 0, PGSIZE);
15         // 其中 W 和 U 标志位可在二级页表中进行进一步的设置;
16         *pde = V2P(pgtab) | PTE_P | PTE_W | PTE_U;
17     }
18     return &pgtab[PTX(va)];
19 }

```

程序 3-3 walkpgdir() 函数
Code 3-3 walkpgdir() function

2. 然后把 a 交给 walkpgdir() 函数 (程序 3-3);
3. walkpgdir() 函数首先从地址 a 中取出最高 10 位作为访问一级页表 pgdir 的下标, 从而找相应的 PDE 所在的单元格, 然后检查该单元格是否为空;
 - 如果为空, 则首先需要分配一个空闲页来作为相应的二级页表, 并把新分配到的该二级页表全部初始化为 0, 最后将该二级页表的物理地址填入到单元格的前 20 位并进行标志位的设置, 即可完成一条 PDE 的写入;
 - 如果该单元内已经存放着 PDE, 并且 PTE_P 这一标志位为 1 的话, 则表明该条 PDE 所对应的二级页表已经被映射了, 此时可直接取出 PDE 的前 20 位地址作为找到二级页表的物理地址。
4. 最后再取出 a 的第 12~21 位做为下标访问该二级页表, 找到相应的 PTE 所对应的单元格地址并将其返回给 mappages() 函数。
5. mappages() 函数检查该单元格内容是否为空, 如果为空, 则把物理地址 pa 填入该地址的前 20 位, 最后按要求对标志位进行设置, 即完成了对二级页表的一条 PTE 的写入。

```

1 | struct run {
2 |     struct run *next;
3 | };

```

程序 3-4 空闲页
Code 3-4 Free page pointer

```

1 | struct {
2 |     struct spinlock lock;
3 |     int use_lock;
4 |     struct run *freelist;
5 | } kmem;

```

程序 3-5 kmem 结构体
Code 3-5 struct kmem

3.2.3 freelist 的实现

内核负责为每一个进程分配和回收内存，为了方便对内存的管理，内核把系统里所有的空闲页集中放在一起，并以链表链表的形式组织起来。内核每次分配内存都是从该链表中拿出一页交给进程；每次回收一个内存页后，把该页加入链表中。内核把物理内存中从内核结束的地方（end）开始到 PHYSTOP 的地方（参见图 3-9）都用作运行时的内存分配区域。

存放所有空闲页的链表叫做 freelist。freelist 里的每一个成员就是一个空闲页。为了定义一个 freelist，这里首先对一个空闲页做出了定义。所谓空闲页，就是什么都没有存放的页面，但是为了能连成一条链表，所有的空闲页都应该有一个指向下一个空闲页的指针。空闲页（run）的定义如程序 3-4 所示。

由于 freelist 有可能被多个 CPU 同时访问，所以，必须用一个锁加以保护，如 spinlock。把 freelist 和 spinlock 打包，一起放在 kmem 数据结构内（程序 3-5）。需要说明的是，系统在初始化时，只启动了一个 CPU，其它的 CPU 尚未初始化，此时，访问 freelist 并不需要使用 lock，所以，在 kmem 里增加一个 use_lock 变量，就是为了控制是否需要使用锁才能访问 freelist。

内存分配是以页为单位的，内核每次从 freelist 链表中取出第一个空闲页交给进程。实现内存分配的函数是 kalloc() 函数（程序 3-6），其主要工作过程是：

```
1 char* kalloc(void) {  
2     struct run *r;  
3     if(kmem.use_lock)  
4         acquire(&kmem.lock);  
5     r = kmem.freelist;  
6     if(r)  
7         kmem.freelist = r->next;  
8     if(kmem.use_lock)  
9         release(&kmem.lock);  
10    return (char*)r;  
11 }
```

程序 3-6 kalloc() 函数
Code 3-6 kalloc() function

1. 首先检查 kmem 里的 use_lock 的变量值，
 - 如果为 0，则表明不需要获得锁即可直接访问 freelist；
 - 如果为 1，则表明需要先获得 spinlock 才能访问 freelist。
2. 接下来 kalloc() 函数取出 freelist 的第一个页面，并重新设置 freelist 指针让其指向该页面的下一个页面；
3. 最后 kalloc() 函数把该页面返回给进程，即完成了一个页面的分配。

在一个程序不再使用某个页面时，内核便把该页面释放掉。页面释放的处理方式是把不要的内存页面全部填充为 1，然后把该页面加到 freelist 中。负责释放页面的函数是 kfree()（程序 3-7）。kfree(char *v) 把参数 v 所指向的物理内存页进行释放，主要工作过程如下：

1. kfree() 函数首先检查地址 v 是否合法：v 不能释放属于内核的页面，也不能释放 PHYSTOP 以上的页面，另外每次释放都是以页为单位的，所以 v 必须是页面大小的整数倍。
2. 接下来，把该页面的内容全部填充为 1，即填入无效内容；
3. 获取操作 freelist 的锁；
4. 把地址 v 指针结构化成 run；
5. 最后再把该页加到 freelist 的表头位置；
6. 释放锁；

```

1 void kfree(char *v) {
2     struct run *r;
3     if((uint)v % PGSIZE || v < end || V2P(v) >= PHYSTOP)
4         panic("kfree"); //不能释放内核所占的页，也不能释放外围设
           ↪ 备所占的页面
5     memset(v, 1, PGSIZE); //把要释放的页面全部填充为 1
6     if(kmem.use_lock)
7         acquire(&kmem.lock);
8     r = (struct run*)v;
9     r->next = kmem.freelist;
10    kmem.freelist = r;
11    if(kmem.use_lock)
12        release(&kmem.lock);
13 }

```

程序 3-7 kfree() 函数
Code 3-7 kfree() function

3.2.4 进程的地址空间

每个进程都有自己独立的虚拟地址空间，都有自己独立的页表，而内核的地址空间在每一个进程页表里都有完整的映射，这样做的好处是方便处理系统调用，异常情况和中断。当进程在运行时，如若发生了这三种情况，此时 CPU 不需要切换页表，不需要进行上下文的保存和重载，而是直接在当前进程的地址空间内便可运行系统调用，异常和中断的处理程序。进程的虚拟地址空间与物理内存空间的映射关系如图 3-9所示。

进程在加载时，内核首先给进程分配一个物理页用于存放一级页表。然后内核再把自己映射到这个页表中。负责把内核映射到每个进程空间中去的函数是 setupkvm() (程序 3-8)。

其中 kmap[] 数组 (程序 3-9) 里规定了内核的各个部分分别被映射到了物理内存的哪个位置。内核的虚拟地址与物理地址的映射关系如下：

- 把从 KERNBASE 开始到 0x100000 即 EXTMEM (KERNLINK) 的这一段虚拟地址映射到从 0 开始到 EXTMEM 的这一个物理段，用以做普通 I/O 设备的存储空间；
- 把从 KERNBASE+0x100000 开始到 data 这一段虚拟地址映射到从 0x100000 到 V2P (data) 的这一个物理段，用来存放内核的代码段和只读数据段；

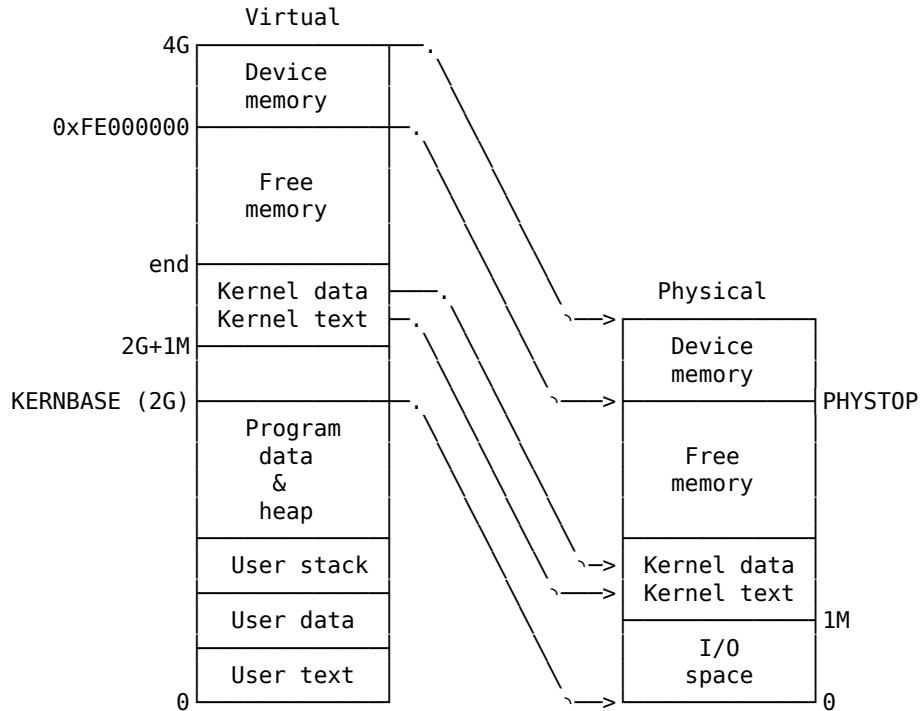


图 3-9 进程的虚拟地址空间与物理内存的映射关系

Figure 3-9 The mapping of virtual address space and Physical address space

- 把从 data 开始到 PHYSTOP 这一段的虚拟地址映射到从 V2P (data) 开始到 PHYSTOP 的这一个物理段，用来存放内核的可读可写的数据段，同时也用作内核的扩张；
- 把虚拟内存的最高 16M 直接映射到物理内存的最高 16M 的地方，用作 DMA 供显卡、网卡等设备的使用。

setupkvm() 函数（程序 3-8）的工作过程主要是：

1. setupkvm() 首先调用 kalloc() 函数为进程分配得一个物理内存页，以作一级页表用；
2. 其次把这个新分配到的页表全部初始化为 0；
3. 接下来确保 PHYSTOP 地址要小于 DEVSPACE；
4. 然后 setupkvm() 调用 mappages(), mappages() 则按照 kmap[] 数组所定义的顺序把内核所有的部分映射到页表中。

```

1 pde_t* setupkvm(void) {
2     pde_t *pgdir;
3     struct kmap *k;
4
5     if((pgdir = (pde_t*)kalloc()) == 0)
6         return 0;
7     memset(pgdir, 0, PGSIZE);
8     if (P2V(PHYSTOP) > (void*)DEVSPACE)
9         panic("PHYSTOP too high");
10    for(k = kmap; k < &kmap[NELEM(kmap)]; k++)
11        if(mappages(pgdir, k->virt, k->phys_end -
12            ↪ k->phys_start, (uint)k->phys_start, k->perm) < 0)
13        {
14            freevm(pgdir);
15            return 0;
16        }
17    return pgdir;
18 }

```

程序 3-8 内核在进程地址空间内的映射

Code 3-8 The mapping of kernel address space in a process

```

1 static struct kmap {
2     void *virt;
3     uint phys_start;
4     uint phys_end;
5     int perm;
6 }
7
8 kmap[] = {
9     {(void*)KERNBASE, 0, EXTMEM, PTE_W}, // 映射普通 I/O
10    {(void*)KERNLINK, V2P(KERNLINK), V2P(data), 0}, // 映射内
11    ↪ 核的代码段和只读数据
12    {(void*)data, V2P(data), PHYSTOP, PTE_W}, // 映射内核的可
13    ↪ 写数据段
14    {(void*)DEVSPACE, DEVSPACE, 0, PTE_W}, // DMA
15 };

```

程序 3-9 内核空间地址映射

Code 3-9 Kernel address space mapping

3.2.5 虚拟内存的实现

前面（第 2.2.1 节）已经讨论过，每个用户进程的地址空间都包含两部分：内核空间和用户空间。在上一节里已经讨论了如何实现把物理内存中的内核映射到每个进程的页表中。接下来将讨论如何实现进程用户空间的内存分配。在给进程分配用户空间时，最直接的办法就是，程序有多大就给它分配多大的空间，但这样做的后果就是，内存空间会消耗得很快，可能没加载几个进程，内存空间就已经耗尽了。在程序大小的膨胀速度远远大于物理内存的增长速度的今天这种方法显然不具备很好的实用性。所以，现代操作系统都通过虚拟内存的技术来实现如何在有限的内存空间内多容纳几个用户进程。实现虚拟内存的技术主要有：按需加载（demand paging）技术和写时复制（copy-on-write）技术^[3]。由于实验时间和资源有限，本实验只选择实验性地实现了其中一项技术：copy-on-write 技术。

3.2.5.1 copy-on-write

copy-on-write（简称 COW，写时复制），是指在创建新进程时，并没有立即为新进程分配物理内存页，而是让母进程和各个子进程共享（只读）一份物理内存空间，直到其中一个进程（子进程或母进程）发生了对某个共享页面进行“写”操作时，才给该进程分配一个新的物理内存页，并把要进行“写”操作的这一个页面的内容从母进程那拷贝一份过来交给子进程。这种只复制要改变的页面的方法相比让每个新创建的子进程都复制母进程一整份的地址空间的方法要节省很多的物理内存。

COW 技术主要用在创建子进程时，为子进程分配物理内存页面的过程中。一般来说，进程在创建以后并不会立即产生“写”操作，也不会立即运行一份新的程序代码，所以，没必要在创建新进程的时候就立刻就把程序全部加载到内存。COW 的做法是把母进程的页面标志为只读页面，并记录每个页面的被引用次数，母进程与所有的子进程共享这些只读页面。当母进程或子进程要对这些共享页面中的某一个页进行“写”操作时，内核首先检查该页面的被引用次数，如果次数等于 1 的话，则直接把该页面的权限从只读改为可写；如果次数大于 1 的话，则表明有多个进程正在共享这个页面，这时候内核将在内存里为该进程申请一个空闲物理

```

1  struct {
2      struct spinlock lock;
3      int use_lock;
4      struct run *freelist;
5      struct pg_ref[PHYSTOP >> PGSHIF];
6  } kmem;

```

程序 3-10 带有 pg_ref[] 数组的 kmem 结构体
Code 3-10 struct kmem with pg_ref[] in it

页面，用来复制这个共享页面的内容，并把这个新的物理页面加到该进程的页表中，然后把该页面的权限改成可写，最后把共享页面的被引用次数减去 1。概括来讲，实现 COW 技术所需完成的核心工作大致如下：

1. 记录每个共享页面的被引用次数；
2. 实现一个 copyvm() 函数，负责把母进程的物理页面映射到子进程的页表中，并把这些页面标志为只读权限；
3. 处理进程发起“写”操作时的页错误（page fault）异常；
4. 每次更新页表后，重新加载页表寄存器。

首先，记录每个共享页面的被引用次数 给每个页面增加一个用于记录被引用次数的变量 pg_ref，并设计两个函数 pg_refInc()（程序 3-11）和 pg_refDec()，分别用于增、减页面的被引用次数。当一个物理页面被分配时，把相对应的 pg_ref 变量的初值设为 1，每当有一个子进程引用这个页面时，pg_ref 的值加 1。相应地，每当有一个进程复制了这个页面时，pg_ref 的值减 1，当 pg_ref 的值减到 0 的时候，这个页面将会被回收。在 kmem 结构体里增加一个数组 pg_ref[] 用于记录每个页面的被引用次数，如程序 3-10所示。

内核每次给新创建的子进程初始化页表时，实际上都是把母进程所映射的物理页重复映射到该子进程的页表中，然后调用 pg_refInc() 函数把每个物理页面的被引用次数都增加 1。当内核需要为某个进程复制一个共享物理页时，便调用 pg_refDec() 函数把该物理页面的被引用次数减 1。pg_refInc() 函数的具体定义如程序 3-11所示。pg_refDec() 函数与 pg_refInc() 函数大同小异，区别仅在于加 1 和减 1 这个操作上，这里不再单独给出 pg_refDec() 函数的具体实现过程。

```

1 void pg_refInc(uint pa) {
2     if(pa<(uint)V2P(end) || pa>=PHYSTOP)
3         panic("pg_refInc");
4     acquire(&kmem.lock);
5     ++kmem.pg_ref[pa >> PGSHIT];
6     release(kmem.lock);
7 }

```

程序 3-11 pg_refInc() 函数
Code 3-11 pg_refInc() function

其次，实现一个支持 COW 的 `copyuvm()` 函数 在 COW 技术中，内核为新创建的子进程的页表做地址空间映射时，实际上是通过遍历母进程的页表，找到母进程所映射的每一个物理内存页，并把其中具有可写权限的页面统统都改成只读权限外加一个 COW 的标志，然后再把这些更改过权限的页面一页一页地映射到子进程的页表中去，完成对子进程的地址空间的映射。负责为子进程做地址空间映射的这项工作是由 `copyuvm(*pgdir, sz)` 函数（附录 A.2.2）完成的，其中，参数 `pgdir` 代表母进程的一级页表，`sz` 代表母进程的虚拟地址空间大小。函数负责从 `pgdir` 中查出虚拟地址 `0~sz` 所映射的每个物理内存页并把这些物理内存映射到子进程的页表中。`copyuvm()` 的主要的工作过程则如下：

1. 首先为子进程分配页表并把内核映射到页表中去；
2. 遍历母进程的页表，查出母进程的所有虚拟地址对应的每一个物理页面；
3. 检查母进程的每一个物理页面的标志位，如果是可写标志，则改成只读和 COW 标志；
4. 复制母进程的每一个物理页面的开始地址 `pa` 和标志位信息 `flags`；
5. 把复制到的 `pa` 和 `flags` 映射到子进程的页表中；
6. 把每个物理页面的被引用次数增加 1；
7. 最后重新加载母进程的页表寄存器。

最后，实现一个处理页错误的异常处理程序 由于共享页面被标志成了只读模式，当母进程或者子进程企图对共享页面进行“写”操作时，系统就会触发一个页错误（page fault）异常。内核对这样的异常情况的处理是：从 `cr2` 寄存器里取出页错误的虚拟地址并检查该虚拟地址是否合法，如果不合法，这个进程会被直接杀死。

如果地址合法，则检查该虚拟地址所对应的物理页面的被引用次数是否大于 1，如果大于 1，则把该物理页面复制到该进程自己的页表中并将其更改成可写权限；如果被引用次数等于 1 的话，则可直接将该物理页面的读写权限改成可写权限即可。本实验实现页错误异常处理的函数是 `pagefault()`（附录 A.2.3）。`pagefault()` 函数对页错误的处理过程如下：

1. 首先从 `cr2` 寄存器里读取出错的虚拟地址；
2. 其次，检查对这个地址的访问是否合法，如果不合法，进程会被直接杀死；
3. 查询进程的页表，找到需要进行写操作的共享物理页的地址；
4. 查看该物理的被引用次数：如果被引用次数为 1 的话，则直接把该页面的权限改成可写权限。如果大于 1，则为进程分配一个新的物理页。
5. 把共享物理页的内容拷贝到新的物理页中去。
6. 把新的物理页映射到进程的页表中，并把该页面的权限设置为可写；
7. 将原来的共享页的被引用次数减 1；
8. 重新加载页表寄存器。

3.2.6 测试 COW

现在已经完成了对 COW 功能的设计与实现，为了验证该技术是否生效，本实验采用一个简单的用户程序 `testCOW.c`（附录 A.2.4）来做个测试。该程序所做的事情主要是：调用 `fork()` 系统调用来创建子进程，并调用 `getfreepages()` 系统调用来输出系统内的空闲页的数目，以此观察这些空闲页面的数目在 `fork()` 前后的变化和某个进程发生写操作前后的变化。`testCOW.c` 程序里分别定义了两个小函数 `test1()` 和 `test2()`。其中 `test1()` 的功能是查看在母进程没有退出情况下，子进程发生写操作前和后的空闲页面的数目变化；`test2()` 的功能是查看在母进程退出后，子进程发生写操作的前和后，系统内的空闲页面数目的变化。输出结果如图 3-10 所示。

```

P
$
$ testCOW
Test1 is running.....
56733 Free pages in system before forking child processes
Child: a=1
56665 free pages before Child changing the value a
Now a is set to 2
56664 Free pages in system now
Parent: a=1
Parent waiting the child to exit
Now 56733 free pages after child exited
Test1 is finished
-----
Test2 is running.....
56733 free pages before fork
56665 free pages after fork And before Parent exits
$ 56733 free pages after Parent exited And before Child making changes
56733 free pages after changes in Child
zombie!
█

```

图 3-10 CoW 测试结果输出

Figure 3-10 CoW test result

3.2.6.1 输出结果分析

test1() 输出结果分析 从图 3-10可看出，在创建子进程后，空闲页的数目由 56733 变成了 56665。在子进程改变了变量 a 的值后（发生了写操作），空闲页的数目由 56665 变成了 56664，即只减少了一个页。由此可看出，此时内存的开销只增加了一个页，即 4kB。而 $56733 - 56665 = 68$ ，这些个页面是用来存放子进程的页表，同时这个数目也是母进程的页表所占的数目。最后，在子进程退出后，系统里的空闲页数目又变回了 $56664 + 68 + 1 = 56733$ 。

test2() 输出结果分析 从图 3-10可看出，在创建子进程后，空闲页的数目有 56733 变成了 56665。之后，母进程并没有等待子进程的运行结束，而是自己先退出了。此时，母进程释放了自己的页表所占用的空间，但其所映射的物理内存页并没有被释放，因为子进程还需使用。此时空闲页的数目变回了 $56665 + 68 = 56733$ 。子进程在母进程退出后，更改了变量 a 的值（即发生了写），此时由于 a 所在的物理页面的被引用次数只剩 1（只有子进程在使用）而已了，所以，系统并没有给子进程再分配一张新的物理页而是让子进程直接在共享页面内进行写操作，所以，系统里的空闲页面并没有减少 1，仍然是 567333。

综上所述，如果没有实现 COW 技术，所有的子进程都复制一份母进程的

址空间的话，创建一个子进程，系统的开销将增加 $(68 - 1) \times 1k - 1 \times n$ 个物理页面。其中， n 代表进程所需更改的页面个数。

3.2.7 exec()

上一节介绍了如何使用 COW 技术让所有的子进程和母进程共享物理内存空间。但是，如果一个子进程在创建运行起来后发现自己要完成的使命跟母进程其实没有多大的联系，即跟母进程并没有存在合作关系，也不需要共享母进程的代码，而是要运行一份跟母进程不相关的程序代码，这时候进程就需要有自己独立的一份运行空间。内核为进程提供了这个服务，进程在创建完毕后，可以通过调用 `exec()` 系统调用来重新设置一份完全独立与母进程的运行空间并运行自己的代码文件。用户进程同过调用 `exec()` 系统调用来告知内核它需要一个新的运行空间来运行某个程序代码，内核接收到这个系统调用后则通过 `exec()` 函数来实现为进程重新分配运行空间并加载进程所要求的程序代码。概括地说，`exec()` 函数主要完成的工作内容如下：

1. 检查所要加载程序文件的 ELF 格式是否正确；
2. 重新为进程分配页表，并重新映射内核到新页表内；
3. 检查 ELF 文件里的每个程序段的大小信息是否合法以及该程序段是否属于可执行程序段；
4. 检查程序段的大小是否存在溢出的可能；
5. 为每个程序段分配内存空间；
6. 把每个程序段加载进内存空间；
7. 分配新程序用户栈；
8. 将进程指向新的页表；
9. 设置 `exec()` 的返回地址为程序代码的入口地址；
10. 释放旧页表所占用的空间；

其中，为进程重新分配新的页表 and 用户运行空间以及如何加载进程的程序代码是 `exec()` 函数工作的核心。程序 3-12 是 `exec()` 函数的部分节选，给出了实现这些功能的主要细节。完整的 `exec()` 实现参见附录 A.2.5。


```

1  struct proghdr ph;
2  pgdir = setupkvm() //分配页表, 并映射内核
3
4  // 读入 program headers
5  sz = 0;
6  for(i=0, off=elf.phoff; i<elf.phnum; i++, off+=sizeof(ph)){
7      if(readi(ip, (char*)&ph, off, sizeof(ph)) != sizeof(ph))
8          ↪ //从 inode 里读入一个 proghdr 到 ph 指向的缓冲区内
9          goto bad;
10         if(ph.vaddr + ph.memsz < ph.vaddr) //防止溢出
11             goto bad;
12         if((sz = allocuvm(pgdir, sz, ph.vaddr + ph.memsz)) == 0)
13             ↪ //为该程序段分配地址空间
14             goto bad;
15         if(ph.vaddr % PGSIZE != 0)
16             goto bad;
17         if(loaduvm(pgdir, (char*)ph.vaddr, ip, ph.off, ph.filesz)
18             ↪ < 0) //把程序段加载到刚分配得的内存空间中去
19             goto bad;
20     }

```

程序 3-12 `exec()` 工作过程 (代码节选)Code 3-12 `exec()` process

`exec()` 函数首先调用 `setupkvm()` 函数 (程序 3-8) 为进程分配得新的页表并且完成把内核映射到其中的工作。接下来, `exec()` 函数把可执行文件里的程序段一个一个地读取到缓冲区内, 并检查每个段的长度值和地址范围是否合法。如果合法, 则调用 `allocuvm()` 函数 (附录 A.2.6) 来为该段分配内存空间。`allocuvm()` 函数负责以页为单位来为该程序段分配所需的空闲页, 并把这些空闲页映射到进程的新页表中。最后 `exec()` 调用 `loaduvm()` 函数 (附录 A.2.7) 把该程序段加载到已分配的内存空间中去。其中, `readi(inode, dst, off, sz)` 函数是从 `inode` 指向的文件里的 `off` 的开始处读取 `sz` 个字节到 `dst` 指定的地方。由于本实验研究的内容是进程管理和内存管理这两个部分, 而 `readi()` 函数则是属于文件系统方面的内容, 所以本实验只是讨论如何使用这个函数, 并没有给出其具体的代码实现。

3.2.8 延迟分配 (lazy allocation)

进程的地址空间里有一块叫堆 (heap) 的区域, 这个区域是供进程在运行的过程进行内存申请或释放使用的。进程在运行的, 如果发现内存不够用, 需要更多的内存的话或者需要释放某些不需要再使用的页面的时候, 则可通过 `sbrk()` 系统调用来告知内核, 自己需要增加多少的空间或缩减多少个字节的空间, 内核接收到这个系统调用后则通过调用 `growproc()` 函数来为进程分配相应的空间。然而, 有些时候程序里会出现申请一大块的内存空间, 然而, 这些空间在进程后来的运行中却很少被使用或者甚至根本不被用到, 例如一个程序申请了一个很大的稀疏数组, 数组里只有少量的几个值, 其余的空间全部是空或零。这时候, 如果也如约地给进程分配一个的数组空间的话, 则会造成这其中大部分的空间被白白的浪费掉。为了解决这个问题, 本实验采取了延迟分配 (lazy allocation) 的方法, 即当遇到进程申请内存空间时, 并没有立即给它分配任何的空间, 而是采取页错误的处理方法, 即当进程真正需要对这个区域进行操作时, 便会促发一个页错误, 此后内核在处理这个页错误的时候才会真正在物理内存里找一个空闲页交给进程。内核对进程的 `sbrk()` 系统调用的处理过程大致是:

- 首先调用 `growproc()` 内核函数, 检查进程的请求是申请内存还是释放内存;
- 如果是释放内存, 则调用直接调用 `deallocvm()` 函数来释放内存;
- 如果进程的请求是申请内存的话, 则通过把进程的虚拟地址空间增加相应的字节的方法来假装已经给进程分配了空间, 而实际上并没有。
- 如果在后期, 进程确实发生了对所申请区域的操作, 则会促发一个页错误;
- 内核接收到这个页错误, 为进程分配空间。

其中, `growproc(int n)` 函数的工作主要是通过检查参数 n 的值来判断进程是需要申请空间还是释放空间。如果 $n > 0$, 则表明进程需要申请 n 个字节的空间, 如果 $n < 0$, 则表明进程需要释放 n 个字节的空间。`growproc()` 函数的具体定义如程序 3-13所示。

`deallocvm()` 函数 (附录 A.2.8) 主要是负责释放进程从 `newsz` 到 `oldsz` 这一段不再需要的内存空间。`deallocvm(pde_t *pgdir, uint oldsz, uint newsz)`

```

1  int growproc(int n)
2  {
3      uint sz;
4      struct proc *curproc = myproc();
5      sz = curproc->sz;
6      if(n > 0){
7          sz += n; //假装给进程分配了空间，实际上只是增加了其虚拟地址
                  ↪ 空间而已；
8      } else if(n < 0){
9          if((sz = deallocvm(curproc->pgdir, sz, sz + n)) == 0)
10             return -1;
11     }
12     curproc->sz = sz;
13     return 0;
14 }

```

程序 3-13 growproc() 函数
Code 3-13 growproc() function

函数的工作过程比较简单：首先检查 `newsz` 的值是否大于 `oldsz` 的值，如果大于，则直接将 `newsz` 返回给程序。否则，取出 `newsz` 所在的虚拟页的开始地址，并从页表里找出从该虚拟地址开始往上直到 `oldsz` 结束的这一段的虚拟地址所对应的每一页物理地址。然后再调用 `kfree()` 函数（程序 3-7）将这些物理页面一页一页地释放，最后把 `newsz` 返回给程序。`kfree()` 函数的定义在前文已经给出了，这里不再重复。

内核对由于延迟分配所产生的页错误的处理方法是现时为进程分配所缺物理的页面，并把该物理页面映射到进程的页表中，完成后便重新加载页表寄存器。为了实现这一个功能，需要在 `pagefault()` 函数里增加一段为进程分配页面并把分配到的页面映射入进程的地址空间中去的代码，最后，由于进程的页表发生了变化，需要重新加载页表寄存器的值，如程序 3-14所示。

为了测试刚刚实现的延迟分配方案是否正确发挥了作用，这里写了个简单的用户程序 `lazyalloc.c`（程序 A.2.9）进行测试。该程序的主要工作方式是调用 `sbrk()` 系统调用向内核申请空间或释放空间，内核接收到请求后进行相应的处理。程序通过观察在调用 `sbrk()` 函数之前和之后系统里剩余的空闲页面的变化来判断延迟分配这一个方案是否正常发挥作用。`lazyalloc.c` 程序的输出结果图如图 3-11所示。

```

1  pagefault()
2  { //延迟分配;
3      uint va;
4      va=PGROUNDDOWN(cr2());
5      char *mem;
6      if((mem = kalloc()) == 0) {
7          cprintf("kalloc out of memory, kill proc %s with pid
           ↪ %d\n", proc->name, proc->pid);
8          proc->killed = 1;
9          return;
10     }
11     memset(mem, 0, PGSIZE);
12     mappages(proc->pgdir, (char *)va, PGSIZE, V2P(mem),
           ↪ PTE_W | PTE_U);
13     lcr3(V2P(proc->pgdir));
14 }

```

程序 3-14 pagefault() 函数
Code 3-14 pagefault() function

```

$
$ lazyalloc

56733 free pages now!

proc just asked for 4kb memory with sbrk system call

56733 free pages After proc raised its request

Now, proc is going to write something to this newly space!
*a=3
After writing, 56732 free pages left!

Now proc is going to release a 4kb

After releasing, 56733 free pages left!
$ █
[lzb@debian:6] 0:bash 1:make 2:bash

```

图 3-11 lazyalloc.c 程序输出结果

3.2.8.1 输出结果分析

从输出结果上可看到，在进程向内核提出需要增加 4kb 的空间之后，系统里的空闲页面数量并没有减少，也就是说内核实际上并没有为进程分配一个物理页面。当进程往自己所申请的空间里写入东西（*a=3）的时候，系统里的空闲页面数目减少了 1，即内核给进程分配一个页面（4kb）。最后当进程发现自己不再使用到这个 4kb 空间的时候，它便向内核提出释放 4kb 的空间，所以，最后系统里的空闲页面数目增加了 1。由此可见，所实现的延迟方案正确发挥了作用。

3.3 进程间的通信（IPC）

在现实社会中，一个人要独立地完成所有的事情是比较困难的，很多时候，人们都需要通过彼此间的合作来完成一件事情，以达到更高更快的效率。在计算机系统里情况也不例外。一件复杂的事情，如果只由一个进程来单独执行的话，可能需要花费很长的时间。如果把这件复杂的事情拆分成几个小进程来运行的话，速度则会快很多。因为在多处理器系统内，这些小进程可以同时运行。这些小进程则通过相互间的合作来完成整个复杂的事情。相互合作的进程则会产生相互通信的需求，因此，如何为相互协作的进程提供一个可靠且简单的通信方式，就成为了内核设计需要解决的一个重要问题。主要的通信方式有：管道通信、消息队列通信和共享内存，其中，消息队列方式主要应用于微内核设计中。和管道通信和共享内存通信则广泛应用于大部分的 POSIX 宏内核设计中。Linux 采用的就是红内核的设计，而本实验是以 Linux 内核为学习榜样，于是选取了共享内存作为进程间通信的方式。

3.3.1 共享内存

共享内存是指拿出其中一个进程里的一部分内存空间来作为共享区域，即所有的合作进程都享受对该区域的读写。如果一个共享区域被设置为可读且可写的话，那么一个进程对该区域的写操作，别的进程都可以通过读来观测到数据的改变。因此，对共享区域的读写有可能会产生竞争条件。前文在介绍进程的地址空间

```
1  #define num_pgs 4
2  #define num_keys 8
3  struct shm{
4      int used;
5      int sz;
6      uint addr[num_pgs];
7      int ref_count;
8  };
9  struct shm shm[num_keys];
```

程序 3-15 shm 结构体

时曾说过每个进程的空间是受保护的，进程不允许访问其他进程的地址空间，然而，在共享内存的通信方式下，这种限制是要被打破的。此时，所有协作的进程通过对共享区域的读写来彼此交流，分工合作，提高整体效率。实现共享内存要解决的主要事情有：

- 提供一个共享内存的抽象数据结构；
- 实现一个创建共享内存的内核函数（`shmget()`），为共享分配空间，并把共享内存页映射到进程的地址空间中；
- 实现一个能可链接到已有的共享内存的函数（`shmat()`）。
- 为用户使用共享内存提供一个接口（系统调用）。

3.3.2 共享内存的实现

首先创建一个共享内存的结构体 `struct shm`，用来存放关于共享内存的相关信息，如共享内存大小（以页面来计算）、所占页面的开始地址和被进程的引用次数以及是否已经被使用了。`shm` 结构体的定义如程序 3-15所示。

其中，`num_pgs` 表示每块共享内存所占的物理页面最大为 4 页，`num_keys` 表示系统里总共最多可有 8 块共享内存，即一个进程最多能使用 8 块共享内存。

3.3.2.1 分配共享内存

如果一个进程提出创建共享内存的申请，内核需要为其分配所需的内存空间，并把这一部分空间映射到该进程的地址空间中。为了实现这个功能，需要定义一个内核函数 `shmget(int key,int sz)`（附录 A.2.10）。其中，`key` 代表共享内存

的标号，由于本实验规定共享内存最多有 8 块，于是标号的值是 0~8，sz 则代表该块共享内存的大小（所占页数）。该函数的主要工作内容有：

1. 首先检查进程的虚拟地址空间是否还足够容纳该共享内存块，如果足够则进行下一步，否则返回 NULL。
2. 按页为共享内存分配物理内存页；
3. 把分配到的物理内存页一一映射到当前进程的地址空间中；
4. 设置该共享内存的属性值；
5. 返回共享内存对应的开始虚拟地址。

shmat() 函数 一个进程想要访问某个共享内存区域的话，则必须首先向内核申请该共享内存的使用权。内核在接收到请求后，首先检查该共享内存是否已经被创建，如果尚未被创建的话，则给进程返回一个 NULL，否则，找到该共享内存的每一个物理页面，然后再这些物理页面一一映射到该进程的地址空间中，最后把该共享内存的被引用次数加 1。shmat() 函数的具体实现参见附录 A.2.11。

最后，为了用户进程能使用共享内存，需要给用户提供两个分别与 shmget() 和 shmat() 对应的系统调用 sys_shmget()（附录 A.2.12）和 sys_shmat()（附录 A.2.13）。

由于实验时间和资源有限，本文只是对共享内存的功能做了初步的实现，最后并没有充足的时间对该功能进行调试。因此，没有能给出该部分功能的测试结果。

4 总结与展望

4.1 总结

进程管理与内存管理是现代操作系统研究内容中的重点，对这两个功能模块的不断研究开发是现代操作系统实现多任务的技术基础。经过一年多来的努力，通过多次实验，本文最终完成了进程管理与内存管理两部分功能的设计与实现，成功实现了多任务的并发运行并解决了进程间的同步问题，还实现了分页机制和二级页表技术，最后还通过虚拟内存技术和延迟复制技术有效地实现了对内存的管理和分配。虽然存在一些尚未完善的功能，但是，总体结果还算是比较符合预期目标的。多年来，基础研究一直是中国学术界和中国企业界的短板。现如今，随着中美贸易战的加剧，这种短板的表现可能会更加明显。现在国家已经认识到这个问题，正在加强基础研究。本文进行操作系统中最基础的内存管理和进程管理研究，对操作系统的开发有一定的理论意义，对林业信息处理也有一定的理论意义。

4.2 本文取得的成果与创新

经过不断地努力和尝试，本文成功实现了进程管理与内存管理的基本功能。在进程管理部分实现了进程的创建、进程的运行，并能进行多进程管理。所有进程基于时间片轮转（round robin）算法分时使用 CPU。最后还实现了进程间的同步，提供了锁机制，以及避免死锁出现的方法。

在内存管理部分使用分页技术实现了对物理内存的抽象化，通过对虚拟地址的重定向实现了进程地址空间的保护，使得多进程可以同时存在于内存中而互不侵犯。实现了进程的加载和地址空间的分配，并为进程提供了运行时内存地址扩

展的方法。并采用了 copy-on-write 技术和延迟分配技术来提高内存的利用率。最后本文还实现了对进程地址空间的回收,包括进程运行过程中释放的内存空间,和进程退出后的整个地址空间。

本文的创新性在于处理用户栈的溢出问题时,为了防止栈的溢出而造成栈下方的用户数据被覆盖而采用了一个在用户栈的下方额外分配一个用户不可访问物理页面,用来将用户栈和用户数据区域隔开的方法。这个方法利用的是栈自身的自上往下自动增长的特点,当栈已经存放满了之后,继续往栈内存放数据的话就会自动增长到栈的下一页,而这一页已经被设置成了用户不可访问,于是继续存放数据的操作就无法达成。本项目就是利用了这一个简单的方法来防止因用户传入的参数过大而导致栈的溢出。

4.3 改进的方向

在虚拟内存技术方面,本文虽然实现了写时复制技术,做到了在创建子进程时节省内存开销的这一步,但是,尚未做到在给进程重新映射地址空间时,为进程提供按需加载的这一项技术,没有在节约内存开销的问题上实现更进一步的优化。在共享内存的实现方面,由于时间和资金的不足,共享内存这一块功暂时没有能成功调试出来。今后,本人将继续不断努力,争取做到完善以上两点的功能。

参考文献

- [1] BAR M. The Linux Process Model[Z/OL]. [Online; accessed 20-Apr-2015]. 2000. <http://www.linuxjournal.com/article/3814#navigation>.
- [2] BRYANT R E, O'HALLARON D R. Computer Systems: A Programmer's Perspective[M]. 2nd ed. [S.l.]: Addison-Wesley, 2010.
- [3] Silberschatz, Galvin, Gagne. Operating System Concepts Essentials[M]. [S.l.]: John Wiley & Sons, 2011.
- [4] HORWOOD E. Z/OS concepts[M]. [S.l.]: z/OS Basic Skills Information Center, 2010.
- [5] LOVE R. Linux Kernel Development[M]. [S.l.]: Addison-Wesley, 2010.
- [6] Silberschatz, Galvin, Gagne. Operating System Concepts With Java[M]. 8th ed. [S.l.]: John Wiley & Sons, 2010.
- [7] Stackoverflow. Does there exist Kernel stack for each process ?[Z/OL]. [Online; accessed 20-Apr-2015]. 2011. <http://stackoverflow.com/questions/6083236/does-there-exist-kernel-stack-for-each-process>.
- [8] Stackoverflow. Kernel stack for linux process[Z/OL]. [Online; accessed 20-Apr-2015]. 2009. <http://stackoverflow.com/questions/886807/kernel-stack-for-linux-process>.
- [9] WANG F. Linux i386 Boot Code HOWTO[Z/OL]. 2004. <http://tldp.org/HOWTO/Linux-i386-Boot-Code-HOWTO/index.html>.

-
- [10] BACH M. The design of the UNIX operating system[M]. [S.l.]: Prentice-Hall, 1986.
 - [11] HALDAR S, ARAVIND A A. Operating Systems[M]. [S.l.]: Pearson, 2010.
 - [12] ARPACI-DUSSEAU R H, ARPACI-DUSSEAU A C. Operating Systems: Three Easy Pieces[M]. 0.91. [S.l.]: Arpaci-Dusseau Books, 2015.
 - [13] MAUERER W. Professional Linux Kernel Architecture[M]. [S.l.]: John Wiley & Sons, 2008.
 - [14] HENZINGER T A, JHALA R, MAJUMDAR R. Race Checking by Context Inference[J/OL]. SIGPLAN Not., 2004, 39(6):1-13. <http://doi.acm.org/10.1145/996893.996844>. DOI: 10.1145/996893.996844.
 - [15] RAYNAL M. Concurrent Programming: Algorithms, Principles, and Foundations[M]. [S.l.]: Springer Science & Business Media, 2012.
 - [16] JONHS M. GNU/Linux Application Programming[M]. [S.l.]: Course Technology, 2008.
 - [17] TANENBAUM A S. Modern Operating Systems[M]. 3rd ed. [S.l.]: Prentice Hall Press, 2007.
 - [18] COULOURIS G. Distributed Systems Concepts and Design[M]. [S.l.]: Pearson, 2012.
 - [19] PADUA D. Encyclopedia of Parallel Computing[M]. [S.l.]: Springer, 2011.
 - [20] CONTRIBUTORS W. Busy waiting — Wikipedia, The Free Encyclopedia[Z/OL]. [Online; accessed 5-March-2018]. 2017. https://en.wikipedia.org/w/index.php?title=Busy_waiting&oldid=815481304.
 - [21] STALLINGS W. Operating Systems: Internals and Design Principles[M]. 7th ed. [S.l.]: Prentice Hall, 2011.
 - [22] DREPPER U. What every programmer should know about memory[J/OL]. Red Hat, Inc, 2007. <http://lwn.net/Articles/250967/>.

- [23] BHATTACHARJEE A, LUSTIG D. Architectural and Operating System Support for Virtual Memory[M]. [S.l.]: Morgan & Claypool, 2017.
- [24] NAYANI A, GORMAN M, de CASTRO R S. Memory Management in Linux: Desktop Companion to the Linux Source Code[M]. [S.l.]: Free book, 2002.
- [25] THOMPSON K. Unix Implementation[J]. Bell System Technical Journal, 1978, 57: 1931-1946.
- [26] DUARTE G. Memory Translation and Segmentation[Z/OL]. [Online; accessed 20-Apr-2015]. 2008. <http://duartes.org/gustavo/blog/post/memory-translation-and-segmentation/>.
- [27] BREY B B. The Intel Microprocessors: 8086/8088, 80186/80188, 80286, 80386, 80486, Pentium, Pentium Pro Processor, Pentium II, Pentium III, Pentium 4, and Core2 with 64-bit Extensions: Architecture, Programming, and Interfacing[M]. [S.l.]: Pearson Education India, 2009.
- [28] Oracle. X86 Assembly Language Reference Manual[Z/OL]. 2012. <http://docs.oracle.com/cd/E19253-01/817-5477/817-5477.pdf>.
- [29] GORMAN M. Understanding the Linux Virtual Memory Manager[M]. [S.l.]: Prentice Hall, 2004.
- [30] 罗志兵. 基于动态规划的基因双序列比对研究[J]. 现代计算机, 2017: 28-33.

附录 A 主要程序清单

A.1 进程管理相关代码

A.1.1 trapframe 结构体

```
1 struct trapframe {
2     // 通用寄存器, 通过 pusha 指令统一压入栈;
3     uint edi;
4     uint esi;
5     uint ebp;
6     uint oesp; // oesp 寄存器一般不会用到;
7     uint ebx;
8     uint edx;
9     uint ecx;
10    uint eax;
11    ushort gs;
12    ushort fs; // 段寄存器
13    ushort es;
14    ushort ds;
15    uint trapno; // 中断向量号;
16    uint err;    // 如果是异常, 压入一个出错码;
17    uint eip;
18    ushort cs;
19    uint eflags;
20    // 如果是从用户态进入内核态则需要保存用户栈寄存器;
21    uint esp;
22    ushort ss;
23 };
```

A.1.2 allocproc() 函数

```
1 static struct proc* allocproc(void)
2 {
3     for(p = ptable.proc; p < &ptable.proc[NPROC]; p++)
4         if(p->state == UNUSED)
5             goto found;
6     return 0;
7 found:
8     p->state = EMBRYO;
9     p->pid = nextpid++;
```

```

10 // 分配一个内核栈
11 if((p->kstack = kalloc()) == 0){
12     p->state = UNUSED;
13     return 0;
14 }
15 sp = p->kstack + KSTACKSIZE;
16 // 为 trapframe 预留空间
17 sp -= sizeof *p->tf;
18 p->tf = (struct trapframe*)sp;
19 sp -= 4;
20 *(uint*)sp = (uint)trapret; //返回到 trapret 处进行 trapframe 内容弹出;
21 sp -= sizeof *p->context; //为 context 预留空间;
22 p->context = (struct context*)sp;
23 memset(p->context, 0, sizeof *p->context);
24 p->context->eip = (uint)forkret; //新进程的第一次运行是从 fork 系统调用的
    ↪ 返回处开始;
25 return p;
26 }

```

A.1.3 fork() 系统调用

```

1 //创建子进程
2 //子进程共享母进程的地址空间;
3 //子进程的第一次运行必须是从 fork 返回处开始;
4 int fork(void){
5     int i, pid;
6     struct proc *np;
7     struct proc *curproc = myproc();
8
9     //分配进程
10    if((np = allocproc()) == 0){
11        return -1;
12    }
13
14    //把母进程的状态复制给子进程
15    if((np->pgdir = copyvm(curproc->pgdir, curproc->sz)) == 0){
16        kfree(np->kstack);
17        np->kstack = 0;
18        np->state = UNUSED;
19        return -1;
20    }
21    np->sz = curproc->sz;
22    np->parent = curproc;
23    *np->tf = *curproc->tf;
24
25    //fork 留在子进程内的返回值应该是 0;
26    np->tf->eax = 0;
27
28    for(i = 0; i < NOFILE; i++)
29        if(curproc->ofile[i])
30            np->ofile[i] = filedup(curproc->ofile[i]);
31    np->cwd = idup(curproc->cwd);
32

```

```

33     safestrcpy(np->name, curproc->name, sizeof(curproc->name));
34
35     pid = np->pid;
36
37     acquire(&ptable.lock);
38
39     np->state = RUNNABLE;
40
41     release(&ptable.lock);
42
43     return pid; //把子进程的 pid 号返回给母进程。
44 }

```

A.1.4 swtch() 函数

```

1  swtch:
2      movl 4(%esp), %eax
3      movl 8(%esp), %edx
4
5      # 保存当前进程的上下文;
6      pushl %ebp
7      pushl %ebx
8      pushl %esi
9      pushl %edi
10
11     # 切换到一个要运行进程的内核栈;
12     movl %esp, (%eax)
13     movl %edx, %esp
14
15     # 弹出下一个要运行进程的上下文;
16     popl %edi
17     popl %esi
18     popl %ebx
19     popl %ebp
20     ret

```

A.1.5 scheduler() 函数

```

1  scheduler(void)
2  {
3      struct proc *p;
4      struct cpu *c = mycpu();
5      c->proc = 0;
6
7      for(;;){
8          //首先打开中断;
9          sti();
10
11         //循环往复地寻找一个状态为 runnable 的进程。
12         acquire(&ptable.lock);
13         for(p = ptable.proc; p < &ptable.proc[NPROC]; p++){
14             if(p->state != RUNNABLE)

```

```

15         continue;
16
17         //切换到被选中的进程;
18         c->proc = p;
19         switchvm(p);
20         p->state = RUNNING;
21         swtch(&(c->scheduler), p->context);
22         switchkvm();
23         c->proc = 0;
24     }
25     release(&ptable.lock);
26 }
27 }

```

A.1.6 exit() 函数

```

1 void exit(void)
2 {
3     struct proc *curproc = myproc();
4     struct proc *p;
5     int fd;
6
7     if(curproc == initproc)
8         panic("init exiting");
9
10    // 关闭进程所打开的文件
11    for(fd = 0; fd < NOFILE; fd++){
12        if(curproc->ofile[fd]){
13            fileclose(curproc->ofile[fd]);
14            curproc->ofile[fd] = 0;
15        }
16    }
17
18    begin_op();
19    iput(curproc->cwd);
20    end_op();
21    curproc->cwd = 0;
22
23    acquire(&ptable.lock);
24
25    // 唤醒正在等待的母进程。
26    wakeup1(curproc->parent);
27
28    // 把孤儿进程交给 init 进程
29    for(p = ptable.proc; p < &ptable.proc[NPROC]; p++){
30        if(p->parent == curproc){
31            p->parent = initproc;
32            if(p->state == ZOMBIE)
33                wakeup1(initproc);
34        }
35    }
36
37    // 转入进程调度程序运行

```



```

38     curproc->state = ZOMBIE;
39     sched();
40     panic("zombie exit");
41 }

```

A.1.7 wait() 函数

```

1  int
2  wait(void)
3  {
4      struct proc *p;
5      int havekids, pid;
6      struct proc *curproc = myproc();
7
8      acquire(&ptable.lock);
9      for(;;){
10         // 扫描整个数组以找到一个已经退出的进程
11         havekids = 0;
12         for(p = ptable.proc; p < &ptable.proc[NPROC]; p++){
13             if(p->parent != curproc)
14                 continue;
15             havekids = 1;
16             if(p->state == ZOMBIE){
17                 // Found one.
18                 pid = p->pid;
19                 kfree(p->kstack);
20                 p->kstack = 0;
21                 freevm(p->pgdir);
22                 p->pid = 0;
23                 p->parent = 0;
24                 p->name[0] = 0;
25                 p->killed = 0;
26                 p->state = UNUSED;
27                 release(&ptable.lock);
28                 return pid;
29             }
30         }
31
32         // 如果一个子进程都没有找到, 则不必要做任何事情, 直接返回-1 值
33         if(!havekids || curproc->killed){
34             release(&ptable.lock);
35             return -1;
36         }
37
38         // 进入睡眠状态, 以等待有子进程运行结束退出
39         sleep(curproc, &ptable.lock);
40     }
41 }

```

A.1.8 testproc.c 程序

```

1  #include "types.h"
2  #include "stat.h"
3  #include "user.h"
4
5  int main(void)
6  {
7      int i,pid,pid1,pid2;
8      int w;
9      int n=100;
10     for(i=1;i<=n;i++)
11     {
12         pid=fork();
13         if(pid<0)
14         {
15             printf(1,"Parent has forked %d procs\n",i-1);
16             printf(1,"proc[] is full now,cannot fork any more\n\n");
17             break;
18         }
19         if(pid==0)
20         {
21             sleep(100+i);
22             printf(1,"Child pid=%d is exiting\n",getpid());
23             exit();
24         }
25     }
26     sleep(300);
27     if((pid1=fork())<0)
28         printf(1,"proc[] is still full after procs exited,forked failed
        ↪ again\n");
29     else
30         printf(1,"fork succeeded with a new proc %d!!!\n",pid1);
31
32     for(;i>30;i--)
33     {
34         w=wait();
35         if(w>0)
36             printf(1,"waited Child pid=%d\n",w);
37     }
38     pid2=fork();
39     if(pid2<0)
40         printf(1,"fork failed anyway\n");
41     else if(pid2>0)
42         printf(1,"fork succeeded with a new proc %d\n",pid2);
43     else
44     {
45         sleep(30);
46         printf(1,"Child proc=%d exited\n",getpid());
47         exit();
48     }
49     printf(1,"parent exited and all left children was passed to initproc\n");
50     exit();

```

```

51 |     return 0;
52 | }

```

A.1.8.1 testproc.c 程序的输出结果

```

$ testproc
Parent has forked 61 procs
proc[] is full now,cannot fork any more

Child pid=4 is exiting
Child pid=5 is exiting
Child pid=6 is exiting
.....
Child pid=24 is exiting
.....
Child pid=63 is exiting
Child pid=64 is exiting
proc[] is still full after procs eixed,forked failed again
waited Child pid=4
waited Child pid=5
waited Child pid=6
.....
waited Child pid=34
waited Child pid=35
fork succeeded with a new proc 65
parent exited and all left children was passed to initproc
zombie!
zombie!
.....
zombie!
Child proc=65 exited
zombie!

```

A.1.9 sleep() 函数

```

1 | void sleep(void *chan, struct spinlock *lk)
2 | {
3 |     struct proc *p = myproc();
4 |
5 |     if(p == 0)
6 |         panic("sleep");
7 |
8 |     if(lk == 0)
9 |         panic("sleep without lk");
10 |
11 |     // 必须获取 ptable 的 lock 才能访问其内部数据;
12 |     // 获取 ptable.lock 的同时, 释放进程所控制的别的暂时不用的 lock;
13 |     if(lk != &ptable.lock){
14 |         acquire(&ptable.lock);

```

```

15     release(lk);
16 }
17 // Go to sleep.
18 p->chan = chan;
19 p->state = SLEEPING;
20
21 sched();
22
23 // Tidy up.
24 p->chan = 0;
25
26 //重新获取进程原来所控制的锁;
27 if(lk != &ptable.lock){ //DOC: sleeplock2
28     release(&ptable.lock);
29     acquire(lk);
30 }
31 }

```

A.2 内存管理相关代码

A.2.1 mappages() 函数

```

1  static int
2  mappages(pde_t *pgdir, void *va, uint size, uint pa, int perm)
3  {
4      char *a, *last;
5      pte_t *pte;
6
7      a = (char*)PGROUNDDOWN((uint)va); //取出 va 所在的页的开始地址;
8      last = (char*)PGROUNDDOWN(((uint)va) + size - 1);
9      for(;;){
10         if((pte = walkpgdir(pgdir, a, 1)) == 0)
11             return -1;
12         if(*pte & PTE_P)
13             panic("remap");
14         *pte = pa | perm | PTE_P;
15         if(a == last)
16             break;
17         a += PGSIZE;
18         pa += PGSIZE;
19     }
20     return 0;
21 }

```

A.2.2 copyuvm() 函数

```

1  pde_t* copyuvm(pde_t *pgdir, uint sz)
2  {
3      pde_t *d;
4      pte_t *pte;
5      uint pa, i, flags;

```

```

6
7   if((d = setupkvm()) == 0) //分配页表并映射内核;
8       return 0;
9   for(i = 0; i < sz; i += PGSIZE){
10       if((pte = walkpgdir(pgdir, (void *) i, 0)) == 0)
11           panic("copyvum: pte should exist");
12       if(!(*pte & PTE_P))
13           panic("copyvum: page not present");
14       if(*pte & PTE_W) {
15           pte &= ~PTE_W; //把可写页面改成只读
16           pte |= PTE_COW; //把页面设置成 copy-on-write
17       }
18       pa = PTE_ADDR(*pte); //找到母进程的每一个物理页面
19       flags = PTE_FLAGS(*pte);
20       mappages(d, (void*)i, PGSIZE, pa, flags); //把母进程的物理页映射到子进程
        ↪ 的页表中
21       pg_refInc(pa); //把页面的被引用次数增加 1
22   }
23   lcr3(V2P(pgdir)); //重新加载母进程的页表寄存器
24   return d;
25 }

```

A.2.3 页错误处理程序 (pagefault())

```

1   void pagefault(uint err_code)
2   {
3       uint va=rcr2();//从 cr2 寄存器里取出出错地址;
4       pte_t *pte;
5       struct proc *proc ;
6       struct cpu *cpu;
7       cpu=mycpu();
8       proc=cpu->proc;
9       if(proc == 0){
10          cprintf("Page fault with no user process from cpu %d, cr2=0x%x\n",
11                  cpu->apicid, va);
12          panic("pagefault");
13      }
14
15      if(va >= KERNBASE || (pte = walkpgdir(proc->pgdir, (void*)va, 0)) == 0
        ↪ ||
16          !(*pte & PTE_P) || !(*pte & PTE_U) || !(*pte & PTE_COW)){
17          cprintf("Illegal virtual address on cpu %d addr 0x%x, kill proc %s with
        ↪ pid %d\n",
18                  cpu->apicid, va, proc->name, proc->pid);
19          proc->killed = 1;
20          return;
21      }
22
23      // 取出所要写的物理页的地址;
24      uint pa = PTE_ADDR(*pte);
25      // 读取该页的被引用次数;
26      uint refCount = pg_refGet(pa);
27      char *mem;

```

```

28     if(refCount > 1) {
29
30         // 分配一个物理页用来复制共享页的内容;
31         if((mem = kalloc()) == 0) {
32             cprintf("Page fault out of memory, kill proc %s with pid %d\n",
33                 ↪ proc->name, proc->pid);
34             proc->killed = 1;
35             return;
36         }
37         // 把共享页的内容复制到新分到的内存页中;
38         memmove(mem, (char*)P2V(pa), PGSIZE);
39         // 将新的内存页写入页表并设置为可写权限;
40         *pte = V2P(mem) | PTE_P | PTE_U | PTE_W;
41
42         // 将原来的页面的被引用次数减 1;
43         pg_refDec(pa);
44     }
45     // 如果只有当前进程引用该物理页面的话, 则直接将其改为可写权限即可;
46     else if(refCount == 1){
47         // remove the read-only restriction on the trapping page
48         *pte &= ~PTE_COW;
49         *pte |= PTE_W;
50     }
51     else{
52         panic("pagefault reference count wrong\n");
53     }
54
55     // 重新加载页表寄存器;
56     lcr3(V2P(proc->pgdir));
57 }

```

A.2.4 COW 测试程序 (testCOW.c)

```

1  #include "types.h"
2  #include "stat.h"
3  #include "user.h"
4
5  // 写一个小程序测试 copy-on-write 功能是否正确发挥作用!
6
7  int a=1;
8  void test1()
9  {
10     printf(1, "%d Free pages in system before forking child
11     ↪ processes\n", getfreepages());
12     int pid=fork();
13     if(pid==0)
14     {
15         printf(1, "Child: a=%d\n", a);
16         printf(1, "%d free pages before Child changing the value
17         ↪ a\n", getfreepages());
18
19         a=2;
20         printf(1, "Now a is set to %d\n", a);

```

```

19     printf(1, "%d Free pages in system now \n", getfreepages());
20     sleep(4);
21     exit();
22 }
23 sleep(3);
24 printf(1, "Parent: a=%d\n", a);
25 printf(1, "Parent waiting the child to exit\n");
26 wait();
27 printf(1, "Now %d free pages after child exited\n", getfreepages());
28 return;
29 }
30
31 void test2()
32 {
33     printf(1, "%d free pages before fork\n", getfreepages());
34     int pid = fork();
35     if(pid==0)
36     {
37         sleep(4);
38         printf(1, "%d free pages after Parent exited And before Child making
39             ↪ changes\n", getfreepages());
40         a = 5;
41         printf(1, "%d free pages after changes in Child\n", getfreepages());
42         exit();
43     }
44     printf(1, "%d free pages after fork And before Parent
45         ↪ exits\n", getfreepages());
46     exit();
47     return ;
48 }
49
50 int main(void)
51 {
52     printf(1, "Test1 is running.....\n");
53     test1();
54     printf(1, "Test1 is finished\n");
55     printf(1, "-----\n");
56     printf(1, "Test2 is running.....\n");
57     test2();
58     exit();
59 }

```

A.2.5 exec() 函数

```

1 int exec(char *path, char **argv)
2 {
3     char *s, *last;
4     int i, off;
5     uint argc, sz, sp, ustack[3+MAXARG+1];
6     struct elfhdr elf;
7     struct inode *ip;
8     struct proghdr ph;

```

```

9   pde_t *pgdir, *oldpgdir;
10  struct proc *curproc = myproc();
11
12  begin_op();
13
14  if((ip = namei(path)) == 0){
15      end_op();
16      cprintf("exec: fail\n");
17      return -1;
18  }
19  ilock(ip);
20  pgdir = 0;
21
22  // 把 elf header 读出来后检查其 magic number;
23  if(readi(ip, (char*)&elf, 0, sizeof(elf)) != sizeof(elf))
24      goto bad;
25  if(elf.magic != ELF_MAGIC)
26      goto bad;
27
28  if((pgdir = setupkvm()) == 0)//分配页表, 并映射内核;
29      goto bad;
30
31  // 一个一个地读入 program header, 然后检查该 phdr 的各个域是否合法。
32  sz = 0;
33  for(i=0, off=elf.phoff; i<elf.phnum; i++, off+=sizeof(ph)){
34      if(readi(ip, (char*)&ph, off, sizeof(ph)) != sizeof(ph)) //从 inode 里
35          ↪ 读入一个 phdr 到 ph 指向的缓冲区内。
36          goto bad;
37      if(ph.type != ELF_PROG_LOAD) //该段是否是 loadable;
38          continue;
39      if(ph.memsz < ph.filesz) //段在内存中的长度不应该小于段在文件中的长度;
40          goto bad;
41      if(ph.vaddr + ph.memsz < ph.vaddr) //防止溢出;
42          goto bad;
43      if((sz = allocvm(pgdir, sz, ph.vaddr + ph.memsz)) == 0)
44          goto bad;
45      if(ph.vaddr % PGSIZE != 0)
46          goto bad;
47      if(loadvm(pgdir, (char*)ph.vaddr, ip, ph.off, ph.filesz) < 0)
48          goto bad;
49  }
50  iunlockput(ip);
51  end_op();
52  ip = 0;
53
54  // Allocate two pages at the next page boundary.
55  // Make the first inaccessible. Use the second as the user stack.
56  sz = PGROUNDUP(sz);
57  if((sz = allocvm(pgdir, sz, sz + 2*PGSIZE)) == 0)
58      goto bad;
59  clearpteu(pgdir, (char*)(sz - 2*PGSIZE)); //把堆栈的下一页设置为 user 不可
    ↪ 访问;
    sp = sz;

```



```

60
61 // Push argument strings, prepare rest of stack in ustack.
62 for(argc = 0; argv[argc]; argc++) {
63     if(argc >= MAXARG)
64         goto bad;
65     sp = (sp - (strlen(argv[argc]) + 1)) & ~3;
66     if(copyout(pgdir, sp, argv[argc], strlen(argv[argc]) + 1) < 0) //把参数
        ↪ 复制到栈内;
67     goto bad;
68     ustack[3+argc] = sp;
69 }
70 ustack[3+argc] = 0;
71
72 ustack[0] = 0xffffffff; // 为用户程序的 main 函数设置一个假的返回地址;
73 ustack[1] = argc; //main 的参数;
74 ustack[2] = sp - (argc+1)*4;
75
76 sp -= (3+argc+1) * 4; //为 ustack[] 数组预留空间;
77 if(copyout(pgdir, sp, ustack, (3+argc+1)*4) < 0) //把 ustack[] 复制到栈内;
    ↪
78     goto bad;
79
80 // Save program name for debugging.
81 for(last=s=path; *s; s++)
82     if(*s == '/')
83         last = s+1;
84 safestrcpy(curproc->name, last, sizeof(curproc->name));
85
86 // 将进程指向新的页表, 并把旧的页表空间释放。
87 oldpgdir = curproc->pgdir;
88 curproc->pgdir = pgdir;
89 curproc->sz = sz;
90 curproc->tf->eip = elf.entry; // main
91 curproc->tf->esp = sp;
92 switchvm(curproc);
93 freevm(oldpgdir);
94 return 0;
95
96 bad:
97 if(pgdir)
98     freevm(pgdir);
99 if(ip){
100     iunlockput(ip);
101     end_op();
102 }
103 return -1;
104 }

```

A.2.6 allocvm() 函数

```

1 int
2 allocvm(pde_t *pgdir, uint oldsz, uint newsz)
3 {

```

```

4   char *mem;
5   uint a;
6
7   if(newsz >= KERNBASE)
8       return 0;
9   if(newsz < oldsz)
10      return oldsz;
11
12   a = PGROUNDUP(oldsz);
13   for(; a < newsz; a += PGSIZE){
14       mem = kalloc();
15       if(mem == 0){
16           cprintf("allocuvm out of memory\n");
17           deallocuvm(pgdir, newsz, oldsz);
18           return 0;
19       }
20       memset(mem, 0, PGSIZE);
21       if(mappages(pgdir, (char*)a, PGSIZE, V2P(mem), PTE_W|PTE_U) < 0){
22           cprintf("allocuvm out of memory (2)\n");
23           deallocuvm(pgdir, newsz, oldsz);
24           kfree(mem);
25           return 0;
26       }
27   }
28   return newsz;
29 }

```

A.2.7 loaduvm() 函数

```

1   int
2   loaduvm(pde_t *pgdir, char *addr, struct inode *ip, uint offset, uint sz)
3   {
4       uint i, pa, n;
5       pte_t *pte;
6
7       if((uint) addr % PGSIZE != 0)
8           panic("loaduvm: addr must be page aligned");
9       for(i = 0; i < sz; i += PGSIZE){
10          if((pte = walkpgdir(pgdir, addr+i, 0)) == 0)
11              panic("loaduvm: address should exist");
12          pa = PTE_ADDR(*pte);
13          if(sz - i < PGSIZE)
14              n = sz - i;
15          else
16              n = PGSIZE;
17          if(readi(ip, P2V(pa), offset+i, n) != n) //从 inode 所指向的文件里
18              ↪ offset+i 开始的地方读取一页内容到 pa 指向的物理页内。
19              return -1;
20      }
21      return 0;
22  }

```

A.2.8 deallocvm 函数

```

1  deallocvm(pde_t *pgdir, uint oldsz, uint newsz)
2  {
3      pte_t *pte;
4      uint a, pa;
5
6      if(newsz >= oldsz)
7          return oldsz;
8
9      a = PGROUNDUP(newsz);
10     for(; a < oldsz; a += PGSIZE){
11         pte = walkpgdir(pgdir, (char*)a, 0);
12         if(!pte)
13             a = PGADDR(PDX(a) + 1, 0, 0) - PGSIZE;
14         else if((*pte & PTE_P) != 0){
15             pa = PTE_ADDR(*pte);
16             if(pa == 0)
17                 panic("kfree");
18             char *v = P2V(pa);
19             kfree(v);
20             *pte = 0;
21         }
22     }
23     return newsz;
24 }

```

A.2.9 程序 lazyalloc.c

```

1  int main(void)
2  {
3      char *a;
4      printf(1, "%d free pages now!\n\n", getfreepages());
5      a = sbrk(4096);
6      printf(1, "\n");
7      printf(1, "proc just asked for 4kb memory with sbrk system call\n\n");
8      printf(1, "%d free pages After proc raised its\n\n", getfreepages());
9
10     printf(1, "\n");
11     printf(1, "Now, proc is going to write something to this newly space!\n");
12     printf(1, "*a=3\n");
13     *a = 3;
14     printf(1, "After writing, %d free pages left!\n", getfreepages());
15
16     printf(1, "\n");
17     printf(1, "Now proc is going to release a 4kb\n\n");
18     a = sbrk(0);
19     a = sbrk(-4096);
20     printf(1, "After releasing, %d free pages left!\n", getfreepages());
21     exit();
22 }

```

A.2.10 shmget() 函数

```

1 void* shmget(int key,int sz)
2 {
3     struct proc *proc;
4     int i;
5     char *mem,*va;
6
7     proc=myproc();
8     if(0<key||key>=num_keys)
9         return NULL;
10    if(proc->key[key]==1)
11    {
12        return proc->vaddr[key];
13    }
14    else if(proc->key[key]==0)
15    {
16        va=(char*)proc->top-sz*PGSIZE;
17        if((uint)va<proc->sz)
18            return NULL;
19        proc->top -=sz*PGSIZE;
20        for(i=0;i<sz;i++){
21            mem=kalloc();
22            if(mem==0)
23            {
24                cprintf("kalloc out of memory\n");
25                proc->killed=1;
26                return NULL;
27            }
28            shm[key].addr[i]=V2P(mem);
29        mappages(proc->pgdir, va, PGSIZE, V2P(mem), PTE_W | PTE_U);
30        va +=PGSIZE;
31    }
32    proc->key[key]=1;
33    shm[key].used=1;
34    shm[key].sz=sz;
35    shm[key].ref_count++;
36    proc->vaddr[key]=proc->top;
37    return proc->vaddr[key];
38 }
39 else
40     return NULL;
41 }

```

A.2.11 shmat() 函数

```

1 void* shmat(int key)
2 {
3     struct proc *proc;
4     int i,sz;
5     char *va;
6
7     proc=myproc();

```

```

8   if(proc->key[key]==1)
9       return proc->vaddr[key];
10  else if(proc->key[key]==0)
11  {
12      if(shm[key].used==0)
13          return NULL;
14      sz=shm[key].sz;
15      va=(char*)proc->top-sz*PGSIZE;
16      if((uint)va<proc->sz)
17          return NULL;
18      for(i=0;i<sz;i++){
19          mappages(proc->pgdir,va,PGSIZE,shm[key].addr[i],PTE_W|PTE_U);
20          va +=PGSIZE;
21      }
22      shm[key].ref_count++;
23      proc->top -=sz*PGSIZE;
24      proc->vaddr[key]=proc->top;
25      return (void*)proc->vaddr[key];
26  }
27  else
28      return NULL;
29  }

```

A.2.12 sys_shmget() 系统调用函数

```

1   int sys_shmget(void)
2   {
3       int key,sz;
4       if(argint(0, &key) < 0)
5           return -1;
6       if(argint(1, &sz) < 0)
7           return -1;
8       return (int)shmget(key,sz);
9   }

```

A.2.13 sys_shmat() 系统调用函数

```

1   int sys_shmat(void)
2   {
3       int key;
4       if(argint(0, &key) < 0)
5           return -1;
6       return (int)shmat(key);
7   }

```

个人简介

罗志兵（1989 ），女，广西贵港人，本科毕业于西南林业大学计算机与信息科学学院，现为在读硕士研究生，就读于西南林业大学大数据与智能工程学院，所学专业为林业信息工程。曾发表的论文有《基于动态规划的基因双序列比对研究》。

导师简介

赵家刚，硕士研究生、副教授，硕士研究生导师，云南省科技项目评审专家，云南省计算机协会理事，主要研究智能数据处理、信息系统开发。主持了多个项目，主编教材 3 部。

主讲的课程有《C 语言程序设计》、《面向对象程序设计》、《数据结构》、《图形图像程序设计》、《人工智能》、《人工神经网络》、《组件技术》、《离散数学》、《计算机编程导论》。

- 主要学习、工作经历：

1978.9 - 1980.7，在腾冲师范读书；

1980.8 - 1983.8，在腾冲固东中学任教；

1983.9 - 1987.7，在云南师大数学系读本科，获理学士学位；

1987.6 - 1998.8，在保山师专任计算机教学工作；

1998.9 - 2001.6，在云南师大计科系读研究生，获理学硕士学位；

2001.7 - 至今，在西南林学院计科系工作。主要从事软件开发的的教学工作，培养了众多编程高手。

- 主要论著和文章：

[1] 赵家刚, 徐声远. ENT 环境下远程处理的教学方法探索[J]. 西南林学院学报增刊, 2002.

[2] 赵家刚, 林毓材. 数据挖掘的关联规则研究[J]. 计算机科学专刊, 2003.

[3] 赵家刚, 王红蕊. 大学计算机程序设计[M]. [出版地不详]: 中国科学技术出版社, 2007.

- [4] ZHAO J, LI S. Prediction Model For Postfire Mortality of Pinus Yunnanensis in central Yunnan Province[J]. ICCAE 国际会议, 2009.
 - [5] 赵家刚. 枚举组合算法的研究与应用[J]. 科技信息, 2009: pp430-431.
 - [6] 赵家刚. C 语言函数教学法探讨[J]. 中国教育研究论, 2009: pp61-65.
 - [7] 赵家刚. 指针的学习与应用[J]. 电脑编程技巧与维护, 2009: pp114-126.
 - [8] 赵家刚, 李俊^①. C 语言程序设计[M]. [出版地不详]: 西南交通大学出版社, 2010.
 - [9] 赵家刚. C 语言指针教学中的知识点分析与总结[J]. 计算机教育, 2011: pp55-61.
 - [10] 赵家刚, 狄光智, 吕丹桔. 计算机编程导论 – Python 程序设计[M]. [出版地不详]: 人民邮电出版社, 2013.
- 主持的项目:
- 1. 2003.6 - 2004.5, 西南林学院, “数据结构教学改革研究”;
 - 2. 2007.5 - 2008.12, 云南海诚集团, “项目建设工程数据库管理软件”, 具有工作流;
 - 3. 2008.6 - 2009.6, 昆明市科计局科技项目审批软件, 具有工作流;
 - 4. 2010.10 - 2013.10, 科学出版社大型教育类网站研发;
 - 5. 2013.10 - 2016.10, 云南省委组织部办公邮件系统。

获得成果目录

- [1] BAR M. The Linux Process Model[Z/OL]. [Online; accessed 20-Apr-2015]. 2000. <http://www.linuxjournal.com/article/3814#navigation>.
- [2] BRYANT R E, O'HALLARON D R. Computer Systems: A Programmer's Perspective[M]. 2nd ed. [S.l.]: Addison-Wesley, 2010.
- [3] Silberschatz, Galvin, Gagne. Operating System Concepts Essentials[M]. [S.l.]: John Wiley & Sons, 2011.
- [4] HORWOOD E. Z/OS concepts[M]. [S.l.]: z/OS Basic Skills Information Center, 2010.
- [5] LOVE R. Linux Kernel Development[M]. [S.l.]: Addison-Wesley, 2010.
- [6] Silberschatz, Galvin, Gagne. Operating System Concepts With Java[M]. 8th ed. [S.l.]: John Wiley & Sons, 2010.
- [7] Stackoverflow. Does there exist Kernel stack for each process ?[Z/OL]. [Online; accessed 20-Apr-2015]. 2011. <http://stackoverflow.com/questions/6083236/does-there-exist-kernel-stack-for-each-process>.
- [8] Stackoverflow. Kernel stack for linux process[Z/OL]. [Online; accessed 20-Apr-2015]. 2009. <http://stackoverflow.com/questions/886807/kernel-stack-for-linux-process>.
- [9] WANG F. Linux i386 Boot Code HOWTO[Z/OL]. 2004. <http://tldp.org/HOWTO/Linux-i386-Boot-Code-HOWTO/index.html>.
- [10] BACH M. The design of the UNIX operating system[M]. [S.l.]: Prentice-Hall, 1986.

- [11] HALDAR S, ARAVIND A A. Operating Systems[M]. [S.l.]: Pearson, 2010.
- [12] ARPACI-DUSSEAU R H, ARPACI-DUSSEAU A C. Operating Systems: Three Easy Pieces[M]. 0.91. [S.l.]: Arpaci-Dusseau Books, 2015.
- [13] MAUERER W. Professional Linux Kernel Architecture[M]. [S.l.]: John Wiley & Sons, 2008.
- [14] HENZINGER T A, JHALA R, MAJUMDAR R. Race Checking by Context Inference[J/OL]. SIGPLAN Not., 2004, 39(6):1-13. <http://doi.acm.org/10.1145/996893.996844>. DOI: 10.1145/996893.996844.
- [15] RAYNAL M. Concurrent Programming: Algorithms, Principles, and Foundations[M]. [S.l.]: Springer Science & Business Media, 2012.
- [16] JONHS M. GNU/Linux Application Programming[M]. [S.l.]: Course Technology, 2008.
- [17] TANENBAUM A S. Modern Operating Systems[M]. 3rd ed. [S.l.]: Prentice Hall Press, 2007.
- [18] COULOURIS G. Distributed Systems Concepts and Design[M]. [S.l.]: Pearson, 2012.
- [19] PADUA D. Encyclopedia of Parallel Computing[M]. [S.l.]: Springer, 2011.
- [20] CONTRIBUTORS W. Busy waiting — Wikipedia, The Free Encyclopedia[Z/OL]. [Online; accessed 5-March-2018]. 2017. https://en.wikipedia.org/w/index.php?title=Busy_waiting&oldid=815481304.
- [21] STALLINGS W. Operating Systems: Internals and Design Principles[M]. 7th ed. [S.l.]: Prentice Hall, 2011.
- [22] DREPPER U. What every programmer should know about memory[J/OL]. Red Hat, Inc, 2007. <http://lwn.net/Articles/250967/>.
- [23] BHATTACHARJEE A, LUSTIG D. Architectural and Operating System Support for Virtual Memory[M]. [S.l.]: Morgan & Claypool, 2017.

- [24] NAYANI A, GORMAN M, de CASTRO R S. Memory Management in Linux: Desktop Companion to the Linux Source Code[M]. [S.l.]: Free book, 2002.
- [25] THOMPSON K. Unix Implementation[J]. Bell System Technical Journal, 1978, 57: 1931-1946.
- [26] DUARTE G. Memory Translation and Segmentation[Z/OL]. [Online; accessed 20-Apr-2015]. 2008. <http://duartes.org/gustavo/blog/post/memory-translation-and-segmentation/>.
- [27] BREY B B. The Intel Microprocessors: 8086/8088, 80186/80188, 80286, 80386, 80486, Pentium, Pentium Pro Processor, Pentium II, Pentium III, Pentium 4, and Core2 with 64-bit Extensions: Architecture, Programming, and Interfacing[M]. [S.l.]: Pearson Education India, 2009.
- [28] Oracle. X86 Assembly Language Reference Manual[Z/OL]. 2012. <http://docs.oracle.com/cd/E19253-01/817-5477/817-5477.pdf>.
- [29] GORMAN M. Understanding the Linux Virtual Memory Manager[M]. [S.l.]: Prentice Hall, 2004.
- [30] 罗志兵. 基于动态规划的基因双序列比对研究[J]. 现代计算机, 2017: 28-33.

致 谢

本课题和论文的完成得到了许多老师和同学的支持和帮助，在这里，我将给予他们最衷心的感谢。在这里，特别感谢我的导师，赵家刚老师的悉心指导和帮助，使得该论文能如期完成。从选择研究方向到确定具体的实施方案，从论文的初稿到最后的审定，无不花费了他大量的心血和精力。赵老师的博学多才，和他在科研学术方面的认真、严谨、求实、创新的态度，以及开拓进取的工作作风都让我收益匪浅。